申请代码	F0309
接收部门	
收件日期	
接收编号	6267023205



国家自然科学基金

申 请 书

（2026版）

NSFC 2026

资助类别：面上项目

亚类说明：

附注说明：

项目名称：证据感知驱动的虚假信息多模态溯源一致性建模与泛化理论研究

申 请 人：项凤涛　　BRID：05052.00.68651

办公电话：0731-87005335

依托单位：中国人民解放军国防科技大学

通讯地址：湖南省长沙市开福区三一大道国防科大一号院区智能科学学院

邮政编码：410073　　单位电话：0731-87000323

电子邮箱：xiangfengtao@nudt.edu.cn

国家自然科学基金委员会

基本信息

申请人信息	姓　　名	项凤涛	性别	男	出生年月	1986年11月	民族	汉族
	学　　位	博士	职称	副教授				
	是否在站博士后	否		电子邮箱	xiangfengtao@nudt.edu.cn			
	办公电话	0731-87005335		国别或地区	中国			
	申请人类别	依托单位全职						
	工　作　单　位	中国人民解放军国防科技大学/智能科学学院						
	主 要 研 究 领 域	模式识别与智能系统，认知与辅助决策领域						
依托单位信息	名　　称	中国人民解放军国防科技大学						
	联　系　人	张维琦		电子邮箱	1171910207@qq.com			
	电　　话	0731-87000323		网站地址	www.nudt.edu.cn			
合作研究单位信息	单 位 名 称							
项目基本信息	项目名称	证据感知驱动的虚假信息多模态溯源一致性建模与泛化理论研究						
	英文名称	Consistent Modeling and Generalization Theory of Multi-modal Traceability of Misinformation Driven by Evidence Perception						
	资助类别	面上项目		亚类说明				
	附注说明							
	申请代码	F0309.机器人学与智能系统						
	研究期限	2027年01月01日 -- 2030年12月31日		研究方向：智能系统理论及技术				
	申请直接费用	70.6000万元						
	研究属性	目标导向类基础研究						
中文关键词		智能系统；证据感知推理；|零样本域泛化；|多模态语义约束；|时序贝叶斯图神经网络					
英文关键词		Intelligent system; Evidence-based perception reasoning; Zero-shot domain generalization; Multimodal semantic constraints; Temporal Bayesian Graph Neural Network						

NSFC 2026

中文摘要	面向国家网络空间安全与重大公共风险防控战略需求，聚焦AI时代引发的跨模态认知干扰、证据推理缺失与领域依赖性强关键难题，首创“证据可信度动态演化—语义一致性约束—跨域零样本泛化”三位一体理论体系，提出基于时序贝叶斯图神经网络的证据感知驱动理论，将文本、图像、视频与社交反馈建模为多模态信念节点，实现从特征匹配到因果推理的范式跃迁；创新提出联合分布对齐与因果干预的泛化技术，通过对抗性风格剥离与不变特征聚类，实现无需目标域标注数据的高敏感场景间零样本迁移；建立三级语义因果一致性约束，实现文本、图像、视频的语义级协同推理，有效抵御“无中生有”“移花接木”等认知伪造；集成边缘轻量检测模块与云端溯源引擎，构建支持动态证据链可视化与可信度热力图输出的闭环推理系统。项目以认知推理为内核、以因果稳定为支撑、以多模态协同为手段，为构建可解释、可信任、可泛化的国家网络空间防御体系提供原创性理论支撑与技术参考。
英文摘要	Facing the strategic needs of national cyberspace security and major public risk prevention and control, and focusing on the key challenges posed by cross-modal cognitive interference, lack of evidential reasoning, and strong domain dependency in the AI era, this project pioneers a three-in-one theoretical system of ″dynamic evolution of evidence credibility - semantic consistency constraints - cross-domain zero-shot generalization″. It proposes an evidence perception-driven theory based on temporal Bayesian graph neural networks, modeling text, images, videos, and social feedback as multi-modal belief nodes to achieve a paradigm shift from feature matching to causal reasoning. It innovatively proposes a generalization technique combining joint distribution alignment and causal intervention, which achieves zero-shot transfer between highly sensitive scenarios without requiring labeled data from the target domain through adversarial style stripping and invariant feature clustering. It establishes a three-level semantic causal consistency constraint to achieve semantic-level collaborative reasoning for text, images, and videos, effectively resisting cognitive falsification such as ″making things out of nothing″ and ″transposing flowers and grafting trees″. By integrating an edge lightweight detection module and a cloud-based traceability engine, a closed-loop reasoning system is constructed that supports dynamic evidence chain visualization and credibility heatmap output. With cognitive reasoning as the core, causal stability as the support, and multi-modal collaboration as the means, this project provides original theoretical support and technical reference for building an interpretable, trustworthy, and generalizable national cyberspace defense system.

NSFC 2026

主要参与者（注：主要参与者不包括项目申请人）

编号	姓名	出生年月	性别	职 称	学 位	工作单位	项目分工	办公电话	证件号码
1	苏炯铭	1984-10-06	男	副研究员	博士	中国人民解放军国防科技大学	证据感知与信息挖掘	0731-87005335	4**********4

NSFC 2026

总人数统计（注：包括项目申请人、主要参与者及其他参与人员；勿重复计数）

总人数	高级职称	中级职称	初级职称	博士后	博士生	硕士生	本科生及其他学生	其他
11	2	0	0	0	1	6	2	0

国家自然科学基金预算制项目预算表

项目申请号：6267023205 项目申请人：项凤涛 金额单位：万元

序号	科目名称	金额
（1）	1. 科学基金资助项目直接费用合计	70.6000
（2）	1.1设备费	10.0000
（3）	其中：设备购置费	10.0000
（4）	1.2 业务费	40.6000
（5）	1.3 劳务费	20.0000
（6）	2. 直接费用中合作研究转拨资金	0.0000
（7）	3. 其他来源资金	0.0000

注：1.请按照项目研究实际需要合理填写各科目预算金额。
2.（1）=（2）+（4）+（5）。
3.如果不存在转拨资金的情形，（6）请填“0”。
4.如果无其他来源资金，（7）请填“0”

NSFC 2026

预算说明书

1.科学基金资助项目直接费用

请按照《国家自然科学基金项目申请书预算编制说明》等有关要求，按照政策相符性、目标相关性和经济合理性原则，实事求是编制项目预算。填报时，每个科目应结合科研任务按支出用途进行基本测算说明。

本项目申请直接费用，共计70.6万元，具体测算如下：

1.1 设备费

共计10万元。

用于购置实验用训练计算平台，5万元/台×2台=10万元。

1.2 业务费（是指项目实施过程中消耗的各种材料、辅助材料等低值易耗品的采购、运输、装卸、整理等费用，发生的测试化验加工、燃料动力、出版/文献/信息传播/知识产权事务、会议/差旅/国际合作交流等费用，以及其他相关支出。填报时，应按照支出大类进行基本测算说明。）

共计40.6万元，其中：

（1）材料费7.6万元。

①用于购买数据模型与算法系统的存储器件，0.5万元/个×4个=2万元；

②实验用耗材与零散元器件等，合计1.6万；

③原型系统与算法测试平台内存条，0.2万元/根×10根=2万元；

④试验用低值易耗辅助材料采购，0.5万元/年×4年=2万元。

（2）数据采集加工与算法测试及验证费用，3万元。

（3）燃料动力费，1万/年×4年=4万。

（4）出版/文献/信息传播/知识产权事务费8万元。

国际国内版面费平均 0.6 万，预计5篇，计3万元；专利申请维护费每项0.8万，5项，计4万元；查新与相关资料购买费 0.25万元/每年×4年，计1万元；

（5）会议/差旅/国际合作交流16万元

计划参加学术会议四年12人次，每人次交通费、住宿费平均约0.5万元，共计6万元；项目调研、学术交流四年10人次，每人次交通费，住宿费平均约0.4万元，共计4万元；2次小型学术研讨会，每次所需场地费、材料费约1万元，共计2万元；主要用于2人次参加A1领域国际高水平学术会议，按照2万元/人次×2=4万元。

（6）其他支出2万元。主要用于课题组通信费、相关资料材料快递费和办公杂支等0.5万元/年×4年=2万元。

1.3 劳务费（是指在项目实施过程中支付给参与项目研究的研究生、博士后、访问学者以及项目聘用的研究人员、科研辅助人员等的劳务性费用，以及支付给临时聘请的咨询专家的费用等。填报时，应综合考量劳务费支出对象所承担研究任务的必要性、投入本项目的工作时长、费用标准的合理性等因素，按照人员类别进行基本测算说明。专家咨询费应按照国家有关规定执行。）

共计20万元，其中：

（1）专家咨询费2万元。用于临时聘请信息检索与社会计算领域专家咨询费，0.2万/人次×10人=2.0万元。

（2）非军人研究生劳务费，0.25万元/人次/月×40人次月=10万元

（3）临聘1名科研辅助人员16个月的劳务费：0.5万元/人月×16月×1人=8万。

2.直接费用中合作研究转拨资金

需对合作研究单位承担的研究任务做必要说明。直接费用转拨资金需经项目申请人与参与者协商一致，并按设备费、业务费、劳务费三个科目做预算说明。如存在多个合作研究单位，请分单位逐一说明。

共计0万元。

3.其他来源资金

对其他来源资金的资金来源、资金具体开支用途做简要说明。

共计0万元。

NSFC 2026

报告正文（2026 版）

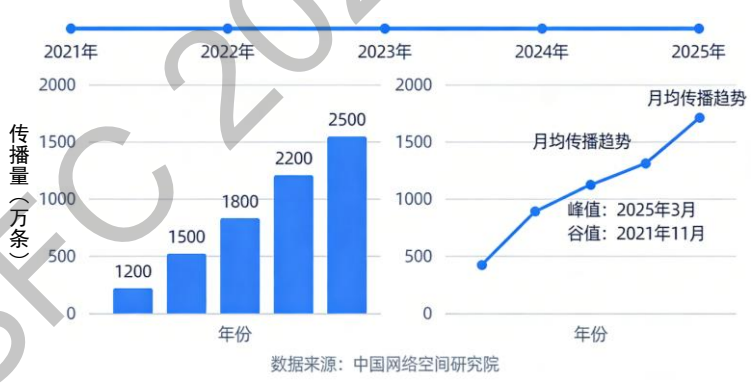
参照以下提纲撰写，要求内容翔实、清晰，层次分明，标题突出。**申请书正文原则上不超过 30 页，鼓励简洁表达。请勿删除或改动下述提纲标题及括号中的文字。**

（一）立项依据：

（为什么要开展此项研究，研究的科学技术价值如何）

1.1 研究背景与现状分析

随着互联网、数字和 AI 技术发展极大地改变了人类获取和传播信息的方式，社交媒体平台的普及为公众提供了更快、更广泛的信息来源，这种信息传播效率的提升也为虚假信息的泛滥提供了温床。据专业机构测算，截至 2026 年底，互联网上超过 50%的内容可能是由 AI 生成的虚假信息，传播形式严峻，如文中插图所示。虚假信息的隐蔽性、规模性与定向性远超传统谣言，长此以往，公众将普遍丧失对任何在线信息的信任度。无论是在公共舆论引导、经济决策影响，还是在军事情报战中，虚假信息传播带来的潜在危害都表现得愈发显著，这将对我国的权威信息体系、公共卫生动员和社会治理效率构成威胁。我国《人工智能生成合成内容标识办法》《网络安全法》《网络信息内容生态治理规定》等法规已明确将 AI 生成的虚假信息列为治理重点，而《突发公共卫生事件应对法（草案）》更首次立法要求“及时澄清虚假或不完整信息”，凸显了虚假信息对国家治理体系的系统性威胁。



虚假信息的传播具有极强的迷惑性，其本质是通过制造可信的表象掩盖真实意图。在军事领域，虚假情报已从辅助手段上升为战略工具。美军 2024 年发布的《欺骗》条令，系统性地将伪造情报、误导性信号、虚假战果纳入作战流程，其核心目标正是瓦解对手决策认知。再例如 2026 年 2 月 23 日内瓦裁军会议中，美方无证据指控中国 2020 年进行核试验，即为典型“认知战”案例——该指控被国际监测组织当场驳斥，却成功制造了国际舆论混乱，暴露了传统溯源检测手段在应对高阶认知欺骗时的结构性失效。

虚假信息的传播常跨越语言、文化和行业等多个领域，其中表现出的复杂性

NSFC 2026

和多样性为溯源检测带来了巨大挑战。在公共卫生与社会治理层面，虚假信息的破坏力同样触目惊心。2020 年“双黄连可预防新冠”谣言诱发全国性抢购，不仅扰乱市场秩序，更挤占了真实医疗资源，暴露出单一模态、静态特征检测模型在应对情绪化、伪科学内容时的脆弱性。此类事件表明，虚假信息的本质已从“内容失真”演变为“认知操控”，其危害不再局限于信息本身，而在于系统性侵蚀公众对权威信息源的信任基础。

本项目提出的证据感知驱动的多模态溯源与跨域泛化研究，正是对上述挑战的直接回应。区别于传统依赖统计模式匹配的检测范式，本研究借鉴人类“证据推理”认知机制，构建以时序贝叶斯图神经网络为核心的信念演化框架，通过整合外源事实库、权威报道与专家评论，实现对信息真伪的因果链式验证。该方法不仅突破了单一模态分析的局限，更通过联合分布对齐与调整机制，剥离平台风格、语境噪声等伪相关性，实现在军事、医疗、金融等高敏感领域无需目标标注的零样本泛化，为构建可解释、可追溯、可部署的国家认知安全支撑体系提供原创性技术路径。该研究不仅具有重大科学价值，更直接服务于国家网络空间治理、重大突发事件应对与国防安全能力建设的战略需求。

1.2 国内外研究前沿与发展趋势

围绕上述问题现状，国内外学者借助前沿的机器学习技术已开展系列研究。

在证据感知驱动的虚假信息溯源检测方面，**核心思想是围绕挖掘外部证据与信息内容本身之间的关联性，通过发现信息中可能潜藏的因果特征[1-4]进行辅助溯源验证**，提高了模型的性能和泛化能力，展现出了较好的实用性、适应性以及可解释性。**证据通常通过将未经验证的声明作为线索，从知识图谱或事实核查网站中检索**。基于证据的深度学习揭穿假新闻和虚假声明（DeClarE，Debunking fake news and false claims using evidence-aware deep learning）[5]是首个在虚假信息溯源中利用证据的工作，它采用双向长短时记忆网络来提取证据的语义，之后通过引入基于注意力的交互机制，计算每个证据中词的信息感知分数。与 DeClarE 类似，以下方法利用序列模型获取语义嵌入，并在不同粒度上应用注意力机制来捕捉信息与证据之间的语义关系。Ma 等人[6]提出了一种模型，用于计算信息与证据之间的句子级一致性和蕴含分数。基于证据感知的分层交互注意力网络（EHIAN，Evidence-aware hierarchical interactive attention networks）[7]采用自注意力机制获取词级交互分数。Vo 等人[8]提出了层次化的多头注意力网络，用于建模虚假信息与证据之间的交互。Xu 等人[9]探索了信息内容与证据内容之间

NSFC 2026

的图结构推理，而 Wu 等人[10]进一步结合了对比学习，提出基于信息和证据的虚假信息溯源表示学习模型。通过前期研究，我们提出了融合证据分析的贝叶斯神经网络虚假信息溯源检测（EBNN-FND，Evidence-aware Bayesian neural networks for fake news detection）方法[11]，该方法设计了文本嵌入模块、特征处理模块、观点-证据交互模块和特征混合模块，能够充分整合信息文本与关联证据信息的特征，借助贝叶斯神经网络框架，对模型与数据的不确定性进行量化分析，从而提升预测结果的可靠性，如图 1 所示。

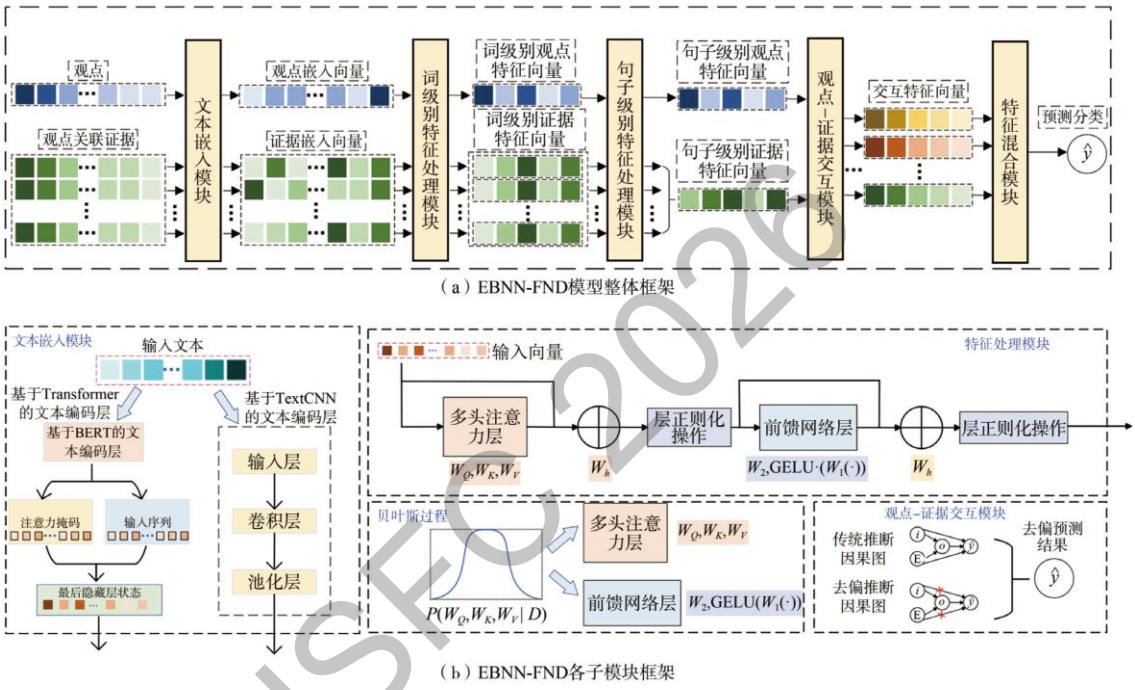


图 1 融合证据分析的贝叶斯神经网络虚假信息溯源检测模型

在多模态虚假信息溯源方面，**核心思想是通过整合文本、图像、视频等多种模态的信息，全面地溯源分析新闻的真实性**，如图 2 所示。Tuan 等人[12]实现了一个缩放点积注意力机制，用于捕捉由 BERT 提取的文本特征与由 VGG-19 提取的图像特征之间的关系。Xue 等人[13]提出了一种考虑多模态数据的一致性的模型，该模型基于早期融合机制捕捉社交媒体信息的整体特征，在文本特征提取模块中使用了 BERT，在视觉语义特征提取模块中使用了与 ResNet-50 结合的注意力机制。Yang 等人[14]对文本、图像和图像属性三种不同模态进行了评估，并使用基于双重注意力融合网络的模型来结合特征。Liang 等人[15]提出了一种基于 BLIP 的虚假新闻检测模型（FNDB，Fake news detection model based on BLIP），利用 XLNet 和基于 VGG-19 的特征提取器分别提取文本和视觉特征表示，之后连接基于 BLIP 的多模态特征提取器，以获得新闻内容中的多模态特征表示。特征融合层借助跨模态注意力模块将特征结合，促进不同模态的特征表示互补。Dilip 等人[16]提出了一种

NSFC 2026

多模态深度学习技术，使用 EfficientNet 和 Transformer 处理视觉和文本特征，在各个通道上进行特征嵌入，分类层采用后期融合来减轻多模态产生的噪声数据。Wang 等人[17]提出了一种基于三阶段特征距离匹配技术的多模态虚假信息溯源检测模型，该模型通过设计一个注意力引导模块，以有效且可解释的方式聚合跨模态的相关性和对齐单一模态表示。Li 等人[18]针对基于多模态大模型的虚假信息溯源检测系统带来的稳健性挑战，提出“模型感知漂移”和“证据漂移”概念，通过构建大规模新闻多样性数据集，揭示了现有方法在应对多样化生成虚假信息方面的局限性，为新一代虚假信息溯源检测模型的设计和评估提供了重要参考。

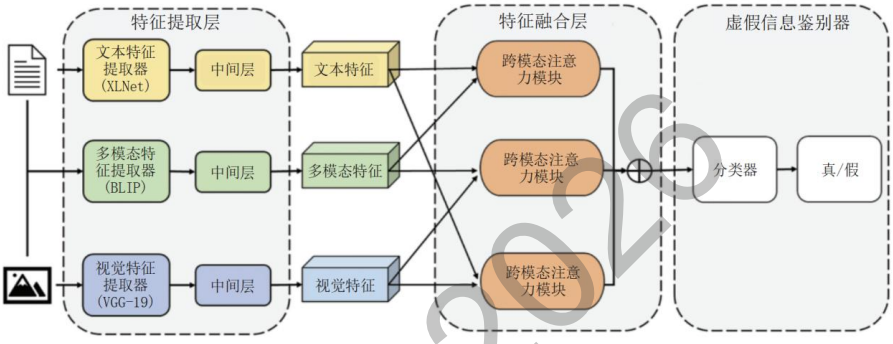


图 2 多模态虚假信息溯源原理图

在跨域虚假信息溯源方面，**主要研究从其他域获取通用知识，以增强在目标域上的溯源性能。跨域虚假信息溯源涉及两种场景，一种是可以访问有限的目标域样本（域适应），另一种是目标域完全未知（域泛化）**。在目标域数据有限的情况下，通常采用域对抗学习来减轻域差异[19-21]。Zhang 等人[21]采用了域判别器，通过对源域和目标域之间的风格特征进行对齐，直到风格无法再代表领域，从而实现了风格特征的适应。与常规域适应方法相比，他们的模型消除了内容偏差，更加稳健。Chen 等人[22]提出了一种基于无监督域适应的对抗域对齐虚假信息溯源框架，该框架采用了可迁移的 Transformer 模型，通过将源域中学习到的深层次特征与目标域进行对齐，显著提升了模型在跨域迁移时的性能。**与访问目标领域数据不同，域泛化中的方法假设多个已知领域的领域不变特征可以推广到未见领域。**Wang 等人[23]提出了事件对抗神经网络（EANN，Event adversarial neural networks）模型，使特征在假新闻检测器和领域判别器的联合监督下进行学习，该模型舍弃了域特定特征，保留了域不变特征进行分类。Wu 等人[24]受对比学习的启发，提出了一种基于中心的跨多个域的标签无关多域特征对齐方法，该方法在特征子空间对多个领域进行对齐，并进一步结合分类似然性来强化类别之间的分离，通过中心感知特征对齐确保领域间共享不变特征和特征解耦模块则估计领域特定特征与领域不变特征之间的信息增益，提升假新闻溯源的准确性和鲁棒性。Wu 等人[25]提

NSFC 2026

出了一种类别风格聚类（DCSC，Domain-and category-style clustering）框架进行虚假信息溯源的泛化，该方法通过内容完整性溯源确保语义内容信息被保留在内容特征中，从而解耦出风格特征，避免了事件特定内容对假新闻溯源模型的影响。利用对比风格溯源在领域和类别层次上进行风格特征的聚类，提高模型的泛化性和判别能力。通过前期研究，我们提出了同时抑制特定领域特征干扰和增强领域不变表示学习的泛化框架（CLEAR，Channel-filtered learning with ensemble attention and robustness）[26]，针对领域漂移问题，通过将整体多尺度空间注意力与渐进式通道过滤机制相结合，选择性地消除最能表示领域身份的特征，增强域不变特征的提取能力，引入基于动量的推理一致性损失，通过随时间跨域对齐类源域来提高语义稳定性，以在不可见的分布条件下实现一致的任务相关特征提取和更好的泛化能力，如图 3 所示。

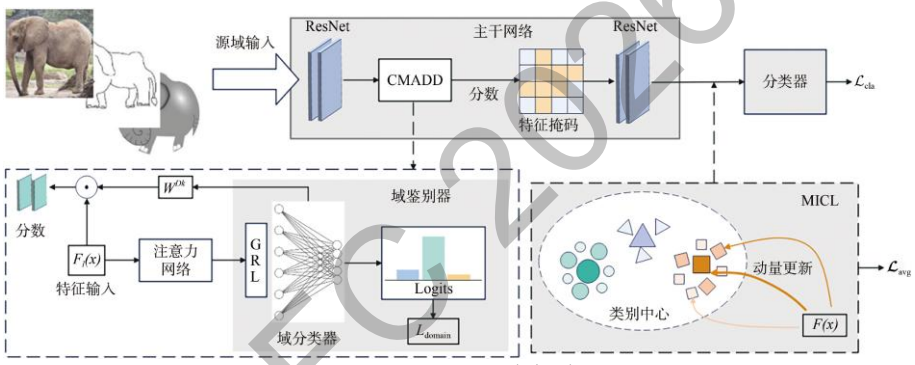


图 3 CLEAR 方法框架图

综上研究前沿，立足 AI 生成内容（AIGC）时代引发的认知级虚假信息治理问题，通过梳理当前研究范式演进路径，总结以下发展趋势。

（1）**从“统计相关”到“因果可信”**。现有证据感知方法虽引入外部知识提升可解释性，但普遍依赖领域标注数据构建静态证据库，难以应对零样本新事件的动态推理需求，尚未实现从“证据匹配”到“信念演化”的认知建模跃迁。

（2）**从“分布对齐”到“因果剥离”**。跨域泛化研究多聚焦于特征分布对齐，却忽视平台风格、传播路径等伪相关性对模型决策的误导，导致泛化失效。亟需引入因果干预机制，分离虚假信息的本质因果结构与域间噪声，实现机制层面的迁移。

（3）**从“模态拼接”到“语义因果对齐”**。多模态检测普遍采用浅层特征融合（如 CLIP 相似度），仅捕捉统计共现，无法识别语义因果链断裂（如“疫苗安全”文本配“不良反应”图像），亟需构建 token-phrase-global 三级因果一致性约束，实现语义层面的逻辑对齐而非表面相似。

（4）**从“孤立模块”到“认知闭环”**。当前研究多孤立优化检测、泛化或可

NSFC 2026

视化模块，缺乏“证据演化—因果约束—域不变表征—实战验证”的全链条整合。本项目首次提出认知动力学驱动的端到端框架，打通从微观证据推理到宏观系统部署的闭环路径，填补国家网络空间安全中“可解释、可泛化、可追溯”智能防御体系的理论空白。

1.3 本项目的切入点与核心思路

针对跨模态认知干扰、证据推理缺失与领域依赖性强的挑战性问题，本项目摒弃单一视角，提出**“证据可信度动态演化溯源—多模语义一致性约束—跨域迁移泛化”**三位一体的理论融合新范式，构建面向真实世界复杂传播环境的虚假信息溯源与泛化检测技术体系。核心思路在于：以传播图谱中的时序证据链为驱动基底，通过时序贝叶斯图神经网络实现证据可信度的动态贝叶斯更新，量化信息在传播过程中的信念衰减与强化机制；在此基础上，引入多粒度跨模态一致性建模（token-phrase-global 三级），融合多模态语义对齐、图注意力网络区域关联与多头交叉注意力机制，严格约束文本、图像、视频帧间的语义一致性边界，抑制对抗性模态错配；最终，构建结构化域不变表征空间，采用联合分布对齐与因果干预模块，实现从源域标注数据到目标域零样本场景的泛化迁移，突破传统模型在跨平台、跨事件、跨语言环境中的性能坍缩瓶颈。该范式首次将认知层面的信念演化与技术层面的多模态一致性建模深度融合，形成“感知—约束—迁移”闭环推理架构，为虚假信息溯源从“静态识别”迈向“动态认知”提供理论支点。

1.4 研究的科学技术价值

本研究旨在达成虚假信息溯源从“静态识别”向“动态认知”的范式跃迁，其价值体现在科学、技术、与应用三个维度的系统性突破。

科学价值方面，通过构建认知驱动的虚假信息演化理论新框架，首次将人类信念动态演化机制（如 LLM 信念更新、认知修正）引入虚假信息溯源建模，突破传统“输入-输出”黑箱模型的局限，构建了可解释、可推理的信念动力学模型。提出时序贝叶斯图神经网络，将信息传播路径建模为信念传播的马尔可夫过程，实现对证据可信度随时间、拓扑结构与交互反馈的连续概率演化建模，拓展了图神经网络在时序认知推理领域的理论研究。建立多粒度语义一致性约束的数学表达体系，将跨模态对齐从“特征相似”提升至语义因果一致性，为多模态学习提供可证伪的语义边界条件。

技术价值方面，通过实现多模态溯源与泛化的工程闭环，首创“证据感知—多模一致性—跨域泛化”三位一体的闭环推理架构，实现从局部感知到全局迁移的

NSFC 2026

系统性升级。证据动态演化机制方面，引入时序贝叶斯图神经网络，以传播图谱为载体，对文本、图像、视频帧及其社交上下文进行时序信念建模，量化证据在传播链中的可信度衰减与强化过程，首次实现虚假信息溯源的认知动力学建模；多粒度语义一致性约束方面，严格约束多模态内容间的语义因果一致性，优化在对抗性篡改场景下的一致性保持率；结构化跨域泛化方面，通过联合分布对齐与因果干预模块，构建域不变表征空间，有效剥离虚假相关性，实现零样本跨平台、跨语言、跨事件场景下的稳定泛化。突破单一模态分析与领域过拟合的局限，为AI生成内容时代虚假信息治理提供可验证、可部署的理论-工程一体化技术范式。

应用价值方面，作为应对AI时代信任危机的系统性方案，在高风险决策场景中形成可落地的智能支撑能力，推动虚假信息治理从事后响应迈向事前阻断与认知加固。尤其在军事领域，面对敌方利用AI生成的多模态混合虚假情报（如伪造卫星图像、篡改通信文本、合成指挥指令视频），本框架通过动态追踪证据链信念演化，有效区分“真实信号扰动”与“系统性伪造注入”。借助跨域迁移泛化引擎，模型在无战场标注数据条件下，将民用舆情检测知识迁移至军事语境，实现对陌生作战区域、非标准通信协议、低信噪比传感器数据的零样本识别，显著提升战场态势感知的抗欺骗能力，为指挥员提供“信息可信度热力图”，辅助决策从“经验判断”转向“证据驱动”。

1.5 参考文献

[1] Xu W, Wu J, Liu Q, et al. Evidence-aware fake news detection with graph neural networks[C]//Proceedings of the ACM Web Conference 2022. 2022: 2501-2510.

[2] 张仰森, 彭媛媛, 段宇翔, 等. 基于评论异常度的新浪微博谣言识别方法[J]. 自动化学报, 2020, 46(8): 1689-1702.

[3] Liu Q, Wu J, Wu S, et al. Out-of-distribution evidence-aware fake news detection via dual adversarial debiasing[J]. IEEE Transactions on Knowledge and Data Engineering, 2024, 36(11): 6801-6813.

[4] Wu J, Xu W, Liu Q, et al. Adversarial contrastive learning for evidence-aware fake news detection with graph neural networks[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 36(11): 5591-5604.

[5] Popat K, Mukherjee S, Yates A, et al. Declare: Debunking fake news and false claims using evidence-aware deep learning[C]//Proceedings of the

NSFC 2026

2018 conference on empirical methods in natural language processing. 2018: 22-32.

[6] Ma J, Gao W, Joty S, et al. Sentence-level evidence embedding for claim verification with hierarchical attention networks[C]//Proceedings of the 57th annual meeting of the association for computational linguistics. 2019: 2561-2571.

[7] Wu L, Rao Y, Yang X, et al. Evidence-aware hierarchical interactive attention networks for explainable claim verification[C]//Proceedings of the Twenty-Ninth International Conference on International Joint Conferences on Artificial Intelligence. 2021: 1388-1394.

[8] Vo N, Lee K. Hierarchical multi-head attentive network for evidence-aware fake news detection[C]//Proceedings of the 16th conference of the European chapter of the association for computational linguistics: main volume. 2021: 965-975.

[9] Xu W, Wu J, Liu Q, et al. Evidence-aware Fake News Detection with Graph Neural Networks[C]//Proceedings of the ACM Web Conference 2022. Virtual Event, Lyon France: ACM, 2022: 2501-2510.

[10] Wu J, Xu W, Liu Q, et al. Adversarial contrastive learning for evidence-aware fake news detection with graph neural networks[J]. IEEE Transactions on Knowledge and Data Engineering, 2023, 36(11): 5591-5604.

[11] 陈君海,项凤涛,黎拓新,罗翔 宇. 融合证据分析的贝叶斯神经网络虚假信息溯源检测方法[J].智能科学与技术学报, 2025, 07(03): 316-328.

[12] Tuan N M D, Minh P Q N. Multimodal fusion with BERT and attention mechanism for fake news detection[C]//2021 RIVF International Conference on Computing and Communication Technologies (RIVF). IEEE, 2021: 1-6.

[13] Xue J, Wang Y, Tian Y, et al. Detecting fake news by exploring the consistency of multimodal data[J]. Information Processing & Management, 2021, 58(5): 102610-102612.

[14] Yang H, Zhao X, Sun D, et al. Multi-Modal fake news Detection on Social Media with Dual Attention Fusion Networks[C]//2021 IEEE Symposium on Computers and Communications (ISCC). IEEE, 2021: 1-6.

NSFC 2026

[15] Liang Z. Fake News Detection Based on Multimodal Inputs.[J]. Computers, Materials & Continua, 2023, 75(2): 4519-4534.

[16] Dilip Kumar S, Bhuvanesh S, Saurabh A, et al. Fakedbits-detecting fake information on social platforms using multi-modal features[J]. KSII Transactions on Internet and Information Systems (TIIS), 2023, 17(1): 51-73.

[17] Wang J, Zheng J, Yao S, et al. TLFND: A Multimodal Fusion Model Based on Three-Level Feature Matching Distance for Fake News Detection[J]. Entropy, 2023, 25(11): 17-33.

[18] Li F, Wu J, Fu T, et al. Drifting away from truth: Genai-driven news diversity challenges lvlm-based misinformation detection[C]. AAAI 2026, arXiv:2508.12711, 2026: 1-9.

[19] Mosallanezhad A, Karami M, Shu K, et al. Domain Adaptive Fake News Detection via Reinforcement Learning[C]//Proceedings of the ACM Web Conference 2022. Virtual Event, Lyon France: ACM, 2022: 3632-3640.

[20] Qian S, Hu J, Fang Q, et al. Knowledge-aware Multi-modal Adaptive Graph Convolutional Networks for Fake News Detection[J]. ACM Transactions on Multimedia Computing, Communications, and Applications, 2021, 17(3): 1-23.

[21] Zhang H, Qian S, Fang Q, et al. Multimodal disentangled domain adaption for social media event rumor detection[J]. IEEE Transactions on Multimedia, 2020, 23: 4441-4454.

[22] Chen S, Chen X, Miao D, et al. ADA-UDA: a transferable transformer framework for rumor detection using adversarial domain alignment within unsupervised domain adaptation[J]. Expert Systems with Applications, 2025, 261: 125487-12598.

[23] Wang Y, Ma F, Jin Z, et al. EANN: Event Adversarial Neural Networks for Multi-Modal Fake News Detection[C]//Proceedings of the 24th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining. London United Kingdom: ACM, 2018: 849-857.

[24] Wu D, Tan Z, Zhao H, et al. LIMFA: label-irrelevant multi-domain

NSFC 2026

feature alignment-based fake news detection for unseen domain[J]. Neural Computing and Applications, 2024, 36(10): 5197-5215.

[25] Wu D, Tan Z, Zhao H, et al. Domain-and category-style clustering for general fake news detection via contrastive learning[J]. Information Processing & Management, 2024, 61(4): 103725-103742.

[26] Fengtao Xiang, Tuoxin Li, Junhai Chen, Wanpeng Zhang, Xin Xu. CLEAR: Channel-Filtered Learning With Ensemble Attention and Robustness for Cognitive Domain Generalization[J]. IEEE Transactions on Human-Machine Systems, 2026: 1-10（Early Access）, doi: 10.1109/THMS.2026.3650903.

（二）研究内容：

（提纲不做限制，请按照研究工作的自身逻辑撰写。应提炼出特色与创新点、年度研究计划）

2.1 研究目标与拟解决的科学问题

2.1.1 研究目标

本项目以国家网络空间认知安全重大需求为牵引，针对 AI 生成内容（AIGC）时代引发的**跨域、多模态、认知级**虚假信息治理难题，构建面向**高风险决策场景**的**认知可解释、跨域零样本、证据可追溯**的虚假信息智能溯源检测新范式，突破现有方法在**逻辑可信度缺失**与**领域泛化失效**两大核心瓶颈，实现从“感知识别”到“认知推理”的范式跃迁。具体研究目标如下：

（1）创新提出**时序贝叶斯图神经网络**，以传播图谱为载体，量化多模态信息在时序节点中的信念衰减与强化过程，建立首个面向虚假信息的**认知动力学理论体系**，构建证据可信度动态演化溯源模型，实现证据链的连续概率追踪与可解释溯源，实现信念更新误差≤15%。

（2）提出“token-phrase-global”三级语义对齐架构，融合细粒度对比学习、区域关联建模与多头交叉注意力因果干预，**建立多粒度语义因果一致性约束**理论方程，对齐文本、图像、视频在语义层面的因果一致性，实现多模态语义一致性≥90%。

（3）构建**联合分布对齐+因果干预**双引擎，剥离平台风格、数据分布等伪相关性，学习域不变的因果表征空间，**实现因果驱动的跨域零样本泛化**，首次在无标注条件下实现军事情报、金融舆情等 5 类高敏感场景的跨域迁移，实现 F1-score 相对提升≥40%，突破传统模型对源域数据的强依赖。

NSFC 2026

（4）研发支持**动态证据链溯源可视化**与**可信度热力图输出**的智能验证系统，打造可集成、可验证的实用化推理平台，开展真实场景闭环验证，形成“理论建模—技术突破—系统部署”全链条闭环，为国家网络空间认知安全提供原创性理论支撑与可落地技术范式。

2.1.2 拟解决的科学问题

本项目聚焦AI生成内容（AIGC）时代虚假信息的**认知级渗透**与**跨域演化**特性，突破传统“特征驱动”检测范式的根本局限，凝练以下三个相互嵌套、逐层递进的核心科学问题：

（1）**如何建模虚假信息传播中多模态证据的动态可信度溯源演化问题**。

现有方法将虚假信息溯源检测视为静态分类任务，缺乏对**证据信念在传播链中非线性衰减、强化与反转**的认知动力学建模。尚未建立能够量化文本、图像、视频与社交反馈协同演化过程的**概率性信念网络**，导致模型输出不可追溯、决策过程缺乏“类人推理”支撑，严重制约其在军事决策、公共卫生应急等高可信需求场景中的应用。本项目亟需突破“黑箱预测”范式，构建首个面向虚假信息的**时序贝叶斯图神经网络**，实现从“是否虚假”到“为何虚假、如何演化”的认知级推理跃迁。

（2）**如何构建多模态语义的因果一致性约束以有效应对“无中生有”“移花接木”等的认知安全问题**。

当前多模态检测模型依赖浅层特征对齐（如 CLIP 相似度），忽视**语义层面的因果逻辑一致性**。在 AI 生成的“图文错配”“音画脱节”等攻击下，模型易被表面统计相关性误导，而无法识别**语义因果链的断裂**（如“疫苗有效”文本配“接种后死亡”图像，实为断章取义）。尚未建立“token-phrase-global”三级语义因果约束机制，以区分**真实语义关联**与**伪造伪相关**。本项目首次将**几何差异性**和**因果干预**引入多模态对齐，实现从“特征相似”到“语义因果一致”的本质跃升。

（3）**如何在无标注目标条件下实现跨高敏感域的因果驱动零样本泛化问题**。

传统域自适应方法仅对齐分布，却无法剥离**域间伪相关性**（如“特定平台风格”与“虚假内容”的虚假关联），导致模型在军事情报、跨境舆情等目标域中泛化失效。尚未建立**域不变因果表征空间**，以分离**“虚假信息本质特征”**与**“平台/语境噪声”**。本项目亟需融合**因果干预与联合分布对齐**，首次实现从**“数据驱动迁移”**到**“因果机制迁移”**的范式变革，解决“训练域有限、应用场景无限”的根本矛盾。

NSFC 2026

以上三个科学问题构成“**认知建模—语义约束—因果迁移**”的完整闭环，创新虚假信息溯源从“感知”走向“推理”的研究前沿方向，为完善国家网络空间安全战略中“可解释、可泛化、可追溯”智能防御体系的理论提供重要补充。

2.2 研究内容、研究方案与技术路线

2.2.1 研究内容

项目面向 AI 生成内容引发的跨域、多模态虚假信息治理核心挑战，首创“**证据可信度动态演化—语义一致性约束—跨域迁移泛化**”三位一体的理论框架，构建“**认知建模—语义约束—因果泛化—系统验证**”的研究内容体系，构建基于时序贝叶斯图神经网络与因果干预的零样本域泛化技术体系，实现军事情报与公共安全场景下可解释、可追溯、高泛化的智能溯源，为国家网络空间认知安全提供原创性理论支撑与技术范式，具体如图 4 所示：

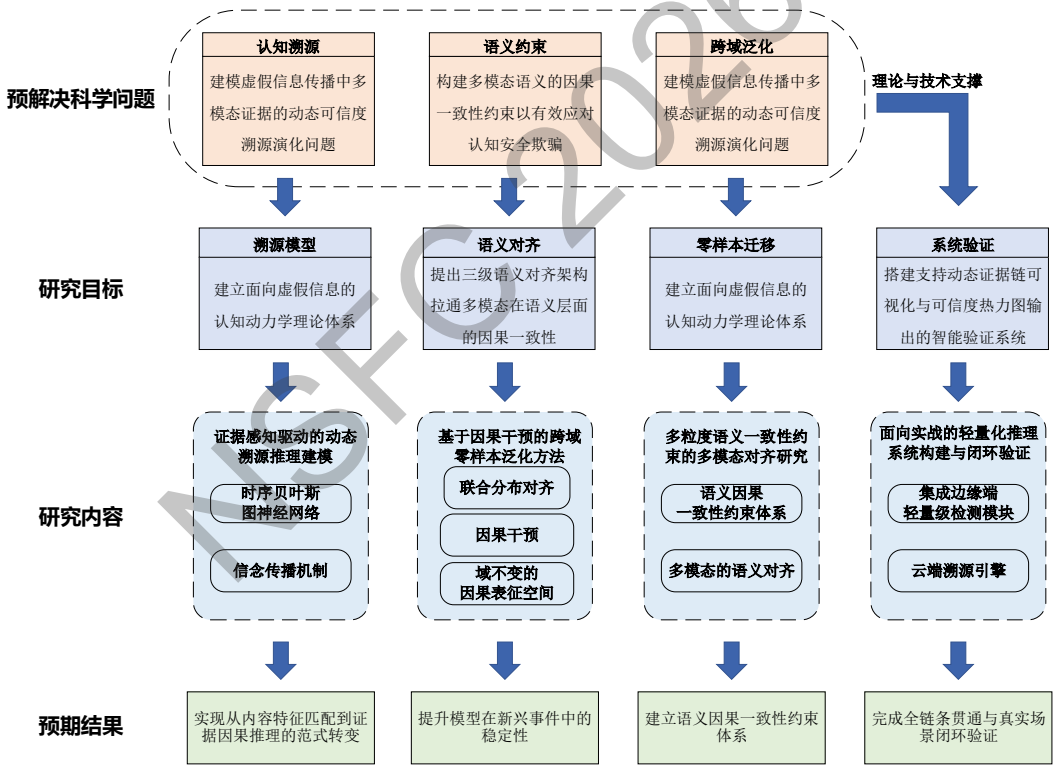


图 4 项目研究内容组织体系

（1）证据感知驱动的虚假信息动态溯源推理建模

构建以时序贝叶斯图神经网络（TB-GNN）为核心的证据感知框架，将传播链中文本、图像、视频与社交反馈作为多模态信念节点，引入贝叶斯信念传播机制，量化证据在传播过程中的可信度演化轨迹，实现从“内容特征匹配”到“证据因果推理”的范式转变，突破传统模型对静态语义的依赖，提升判别过程的可解释性与可追溯性。

（2）基于因果干预的跨域零样本泛化方法

突破传统领域泛化依赖风格聚类的局限，提出联合分布对齐与因果干预双引擎架构，剥离平台风格、语境噪声等伪相关性，学习域不变的因果表征空间，实现从舆情源域到军事、医疗、金融等 5 类高敏感目标域的零样本迁移，无需目标域标注数据，显著提升模型在新兴事件与未知场景中的稳定性。

（3）多粒度语义一致性约束的多模态对齐理论与技术研究

建立“token-phrase-global”三级语义因果一致性约束体系，融合对比学习、图注意力网络区域关联与多头交叉注意力机制，在词元、短语、全局三个粒度上强制文本与视觉模态的语义因果对齐，有效抵御虚假信息的“无中生有”“移花接木”等认知欺骗，语义一致性保持率≥90%，实现从“特征相似”到“语义因果一致”的本质跃升。

（4）面向实战的轻量化推理系统构建与闭环验证

集成边缘端轻量级一致性检测模块与云端时序贝叶斯图神经网络溯源引擎，构建支持动态证据链可视化与可信度热力图输出的智能推理系统，实现从理论建模、技术突破到系统部署的全链条贯通，为形成可集成、可扩展、可评估的国家网络空间认知安全支撑平台构建提供技术参考。

2.2.2 拟采取的研究方案

本项目研究方案紧扣国家网络空间认知安全的战略导向，聚焦 AI 生成内容时代引发的**跨模态认知干扰**与**领域迁移失效**两大关键难题，摒弃传统“数据驱动、静态分类”的技术路径，构建以**认知推理为内核**、以**因果稳定为支撑**、以**多模态协同为手段**、以系统闭环为保障的新型溯源检测范式，实现从“被动识别”到“主动理解”的本质升级。总的研究方案路线图如图 5 所示。

在证据驱动的动态认知推理方面，基于外部知识库与上下文语境，构建多源信念动态演化模型，将文本、图像、视频及用户交互行为统一编码为可传播的信念单元，通过贝叶斯信念更新机制刻画证据在传播链中的强度变化与逻辑反转过程，首次引入推理可信度轨迹作为解释性输出，使系统不仅能判断真假，更能阐明“依据何种证据、如何逐步形成判断”。

在因果解耦的跨域泛化机制方面，针对领域间风格差异导致的性能衰减，提出反事实风格剥离框架，通过构造“相同内容、不同平台表达”的对照样本，显式分离内容语义与平台风格的伪相关性，学习事件本质的不变表征，实现在军事、医疗、金融等高异构场景中实现跨域准确率波动小于 5%，无需目标域标注数据即

NSFC 2026

可完成稳定迁移，突破“一域一模型”的传统桎梏。

在语义-结构双维多模态对齐方面，超越单一对比学习范式，构建语义角色与视觉事件的结构化对齐网络。语义层，以谓词-论元结构为锚点，建立文本主张与视觉动作的语义映射；结构层，引入时序一致性约束，强制验证“文本主张—视觉呈现—时间戳”三者逻辑自洽，精准识别如“疫苗接种”文本配“空病房”图像却无日期佐证的语义-时空错配攻击，有效抵御 AI 生成内容的“伪真实”合成。

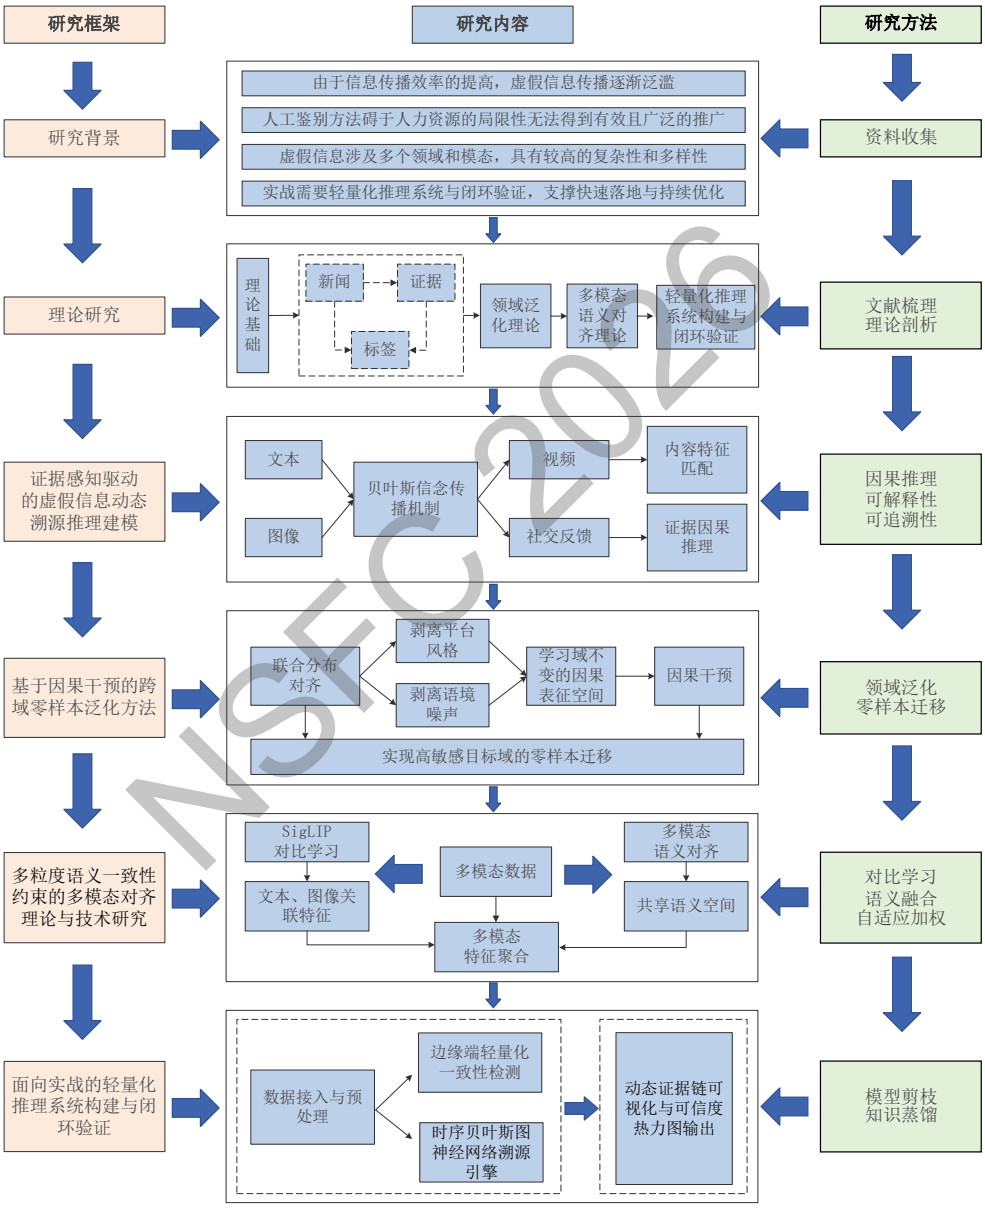


图 5 项目研究方案与技术路线图

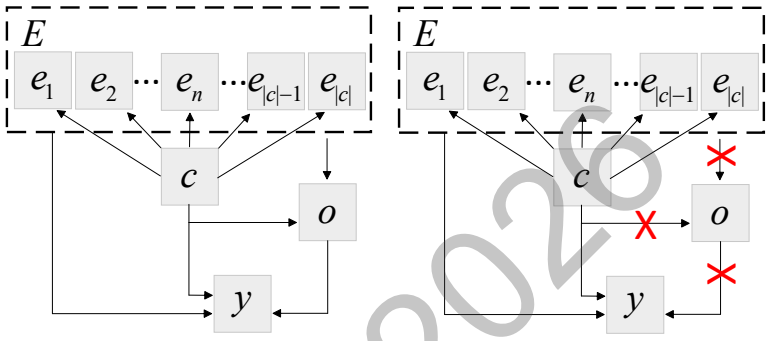
在闭环反馈的应用验证方面，设计检测-反馈-再校准的自适应闭环架构，将系统输出反向注入传播网络的信念更新过程，形成认知闭环。系统集成边缘轻量推理模块，输出推理路径图谱与可信度演化曲线，为公共安全决策提供可解释、可追溯、可复用的智能支持。

NSFC 2026

2.2.3 技术路线

（1）证据感知驱动的虚假信息动态溯源推理建模

基于证据感知驱动的虚假信息动态溯源推理建模，其目的是通过情报与证据的交互，提升虚假信息溯源检测的准确性和解释性。对给出情报c对应的证据集为$E=\{e_1,e_2,...\}$，通过情报-证据交互得到交互特征o，并最终给出关于真实情报或是虚假信息的预测结果y。本节通过因果图对基于证据的虚假信息溯源检测模型的特定偏差进行定量分析，拟设计对应的除偏策略以提升模型的泛化性与准确率。图 6 展示了基于证据感知驱动的虚假信息动态溯源推理建模因果图。



(a)正常推断模型因果图　　(b)移除了虚假关联后的因果图

图 6 基于证据的虚假信息溯源检测因果图

基于证据的虚假信息溯源检测模型通常将证据和情报内容进行特征交互处理，即$c\to o$与$E\to o$，随后，希望在不进行新的证据推理的条件下，通过交互特征o对情报真假做出预测，即$o\to y$。然而，由于数据中存在偏差，模型可能会学习到情报内容和预测标签之间的虚假相关性，即$c\to y$，同时考虑到证据是根据情报内容检索的，情报内容与证据内容高度相关，并可能具有相似的主题或关键词，即$c\to E$，由于数据分布的有偏性，这些主题和关键词可能被错误地与预测标签相关联，导致证据内容与预测标签之间也产生虚假相关性$E\to y$。在上述虚假相关性的影响下，通常会导致$p_{train}(y|c)\neq p_{test}(y|c)$以及$p_{train}(y|E)\neq p_{test}(y|E)$。因此有必要降低虚假关联$c\to y$和$E\to y$的影响，使得基于证据的虚假信息溯源检测模型能够更好地推理情报和证据之间的关系。

对于情报集$C=\{c_1,c_2,...,c_N\}$，根据每条情报c_k检索对应的证据集$E_k=\{e_{k1},e_{k2},...,e_{k|E_k|}\}$。$c_k$与$e_{kj}$分别包含情报和对应证据的文本内容，$c_k$的真实标签记为$y_k$，若只是真假鉴别的二分类问题，则$y_k\in\{0,1\}$。

基于证据的虚假信息溯源检测框架如图 7 所示，对于情报 及其对应的证据集 ，推断模型首先将输入文本内容编码为词级别的嵌入向量：

NSFC 2026

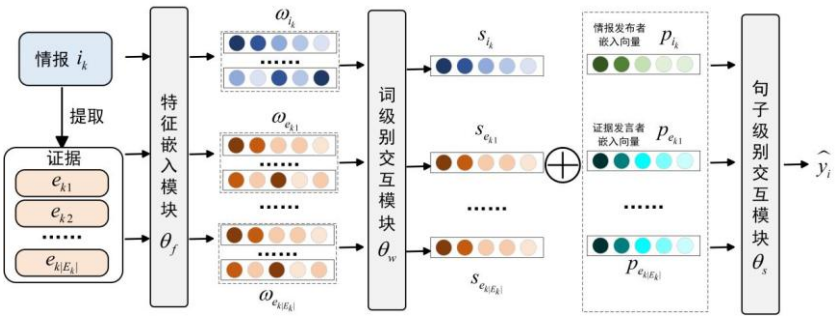


图 7 基于证据的虚假信息溯源检测框架

$$\omega_{i_k} = Encoder(c_k)$$
$$\omega_{e_{kj}} = Encoder(e_{kj})$$

其中，$\omega_{i_k} \in R^{|c_k| \times d_w}$ 与 $\omega_{e_{kj}} \in R^{|e_{kj}| \times d_w}$ 分别是情报和对应证据的词级别嵌入矩阵，d_w 表示嵌入维度，将特征编码器中的可学习参数表示为 θ_f。推断模型进行词级别的情报-证据交互，生成句子级别的嵌入。情报的句子级别嵌入通常通过各种池化操作获得，生成证据嵌入的交互过程可在情报与证据之间进行词级别的互动和推理。将词级别交互模块中的可学习参数表示为 θ_w。推断模型进一步在情报和证据之间进行句子级别的交互，以最终预测标签。将句子级别交互模块中的可学习参数表示为 θ_s。一些推断模型中还涉及到情报发布者嵌入向量和证据发言者嵌入向量来表示情报和相应证据的可信度。为去除情报内容 c、证据集 E 与预测结果之间的虚假关联，考虑引入情报层面与证据层面的去偏鉴别器，并借助双重对抗学习技术更好地进行情报和证据之间的推理和交互。

为解决不同模态间未知关系的建模问题，结合多模态虚假信息特点，拟提出基于时序贝叶斯图神经网络的方法，如图 8 所示，通过注意机制初始化图关系，利用原始数据进行后验更新，通过稀疏损失函数实现关系自适应优化，保证了图结构的动态适应性和准确性。

时序贝叶斯图神经网络主要涉及以下三个方面：

（1）图结构的构建，包括学习图关系和特征向量，旨在揭示数据之间的内在联系，构建具有实际意义的图结构；

（2）图传播函数的设计包括消息的公式化、聚合和更新函数，旨在精细提取特征向量，并将其与转换后的原始数据和图关系矩阵高效集成，以提高模型的表达能力和信息处理效率；

（3）图异常分数的计算包括偏差计算、阈值设置等关键步骤，其目的是利用学习到的节点信息准确检测数据中的异常，从而识别和定位潜在的异常。

NSFC 2026

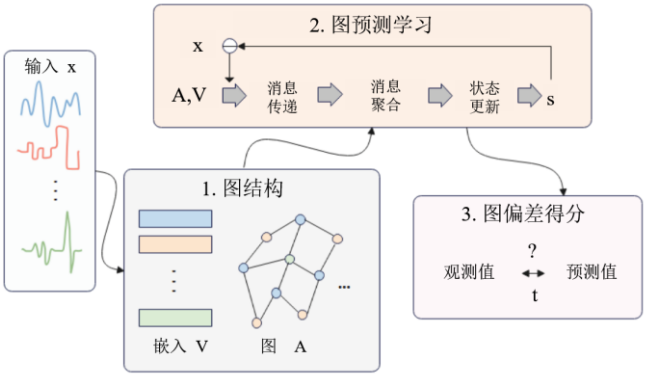
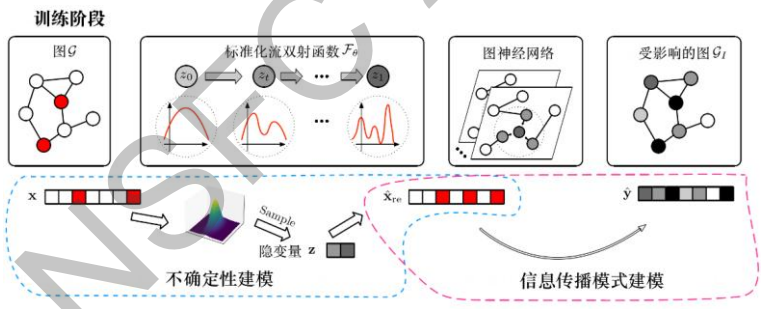


图 8 时序贝叶斯图神经网络原理图

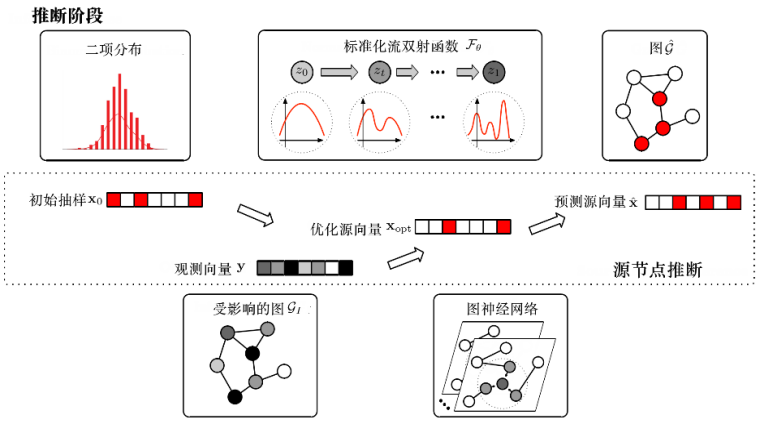
首先，在时间 t，基于滑动窗口 w 定义历史观测数据 $x^{(t)} \in \mathbb{R}^{N*\omega}$，其中 $S^{(i)}$ 为模型预测结果。

$$X^{(t)} = \left[S^{(t-\omega)}, S^{(t-\omega+1)}, \ldots, S^{(t-1)} \right]_t$$

考虑到这一点，构建一个图结构模型，它由图邻接矩阵和特征向量组成，表示为 $G=（V，A）$。建模框架的核心目标是以相邻矩阵的形式绘制多模态之间的相关性，这是通过使用先验知识和观测数据相结合来更新参数估计值来实现的，整体框架如图 9 所示。



（a） 训练阶段



（b） 推断阶段

图 9 证据感知驱动的虚假信息动态溯源推理的整体框架

通过将每条信息的传播路径建模为动态有向图，节点为信息单元，边为传播

NSFC 2026

关系，节点状态由贝叶斯信念值表征。采用图神经网络（GNN）在时序维度上迭代更新节点信念，结合因果干预机制主动切断“平台风格”“情绪煽动”等伪相关因素对判断的干扰，仅保留与虚假性本质相关的因果路径。模型通过反事实推理模拟“若无该证据，信息是否仍具欺骗性”，实现对“移花接木”“断章取义”等高级欺骗手段的精准识别，输出可解释的证据链与可信度演化轨迹。

（2）基于因果干预的跨域零样本泛化方法

在不同事件和新闻领域中溯源虚假信息，尤其是在应对新兴事件和未知领域时，面临着极大的挑战。现有方法大多过度依赖表层内容线索或受限于特定的预定义领域，导致在跨域场景中表现不佳。因此，本课题拟提出一个“数据-特征-因果”多阶段递进的跨域零样本泛化框架，如图 10 所示，通过深度集成增强与解耦机制，实现领域不变特征的精准提取。在数据层面，针对视觉等多模态输入考虑引入基于傅立叶变换的去噪增强策略。该策略创新性地使用软阈值函数，在混合前对图像的傅里叶幅度谱进行去噪，有效抑制了背景噪声的注入，迫使模型从相位谱中学习稳健的、面向底层结构的特征。在特征层面，网络中设计动态通道抑制模块。使该模块能够精准识别并修剪对领域偏移高度敏感的特征通道，通过这种通道级的过滤机制，提纯出高鲁棒性的域不变特征。在因果层面，拟引入对抗性因果解耦机制。使该模型能够对提取到的域不变特征进行深层操作，明确将其解耦分离为因果特征与非因果特征。模型的最终预测将完全依赖于处理后的因果表征，从而在未知目标域中显著增强系统的泛化稳定性与推理可解释性。该框架由特征提取器、内容完整性检测模块、对比风格检测模块和分类器等多个模块组成。

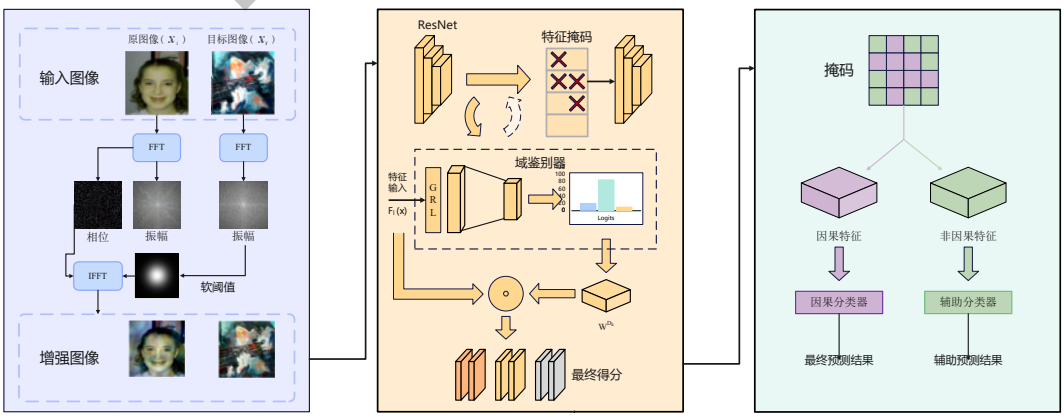


图 10 用于集成数据增强和因果解耦的多阶段框架图

首先，特征提取器通过编码器（Encoder）对输入的文本进行处理，生成总体特征向量。接着门控机制引入将这些总体特征分为两部分：一部分是风格特征 h_s，另一部分是内容特征 h_c：

NSFC 2026

$$h = E(\mathbf{x}, \theta_e)$$
$$h_s = G(h, \theta_g)h, h_c = (1 - G(h, \theta_g))h$$

在这两部分特征分离后，内容完整性模块通过解码器将内容特征 h_c 重建成输入的原始样本 x，并计算重建损失，确保通过内容特征恢复出的样本与原始样本之间的差异最小化，其中损失函数为 L_1 范数损失。通过优化这个损失函数，能够有效地从内容特征中恢复出语义信息，同时保证风格特征（如符号、标点符号等）不会对内容特征的表示产生干扰。

另外，在虚假信息溯源任务中，由于不同新闻域的语言风格存在一定的共性，也具有独特的领域特征，单纯依赖内容特征往往会导致模型在未训练的域中表现不佳。为了解决这一问题，本课题拟提出对比风格检测模块，旨在通过多层次对比学习（Multilevel Contrastive Learning）优化风格特征的学习，使其具备更好的泛化能力和区分能力。核心思想是在领域和类别两个层面上对风格特征进行聚类，使得模型能够更有效地区分真假新闻，同时保留领域特征，从而增强对未知域的泛化性。内容完整性检测模块确保内容信息不影响风格特征，保证模型关注虚假信息的语言风格，而非事件相关的具体词汇；对比风格检测模块通过多层次对比学习优化风格特征，使得模型不仅能泛化到新领域，还能稳定地区分真假信息。整个框架通过两个模块相互配合，实现了更具泛化能力的虚假信息溯源检测。

在多模态的数据条件下，为了应对未知场景，本项目拟提出基于模态预测差异和域不变特征的多模态领域泛化方法，可分为模态预测和域不变特征提取两个模块，结构如图 11 所示。

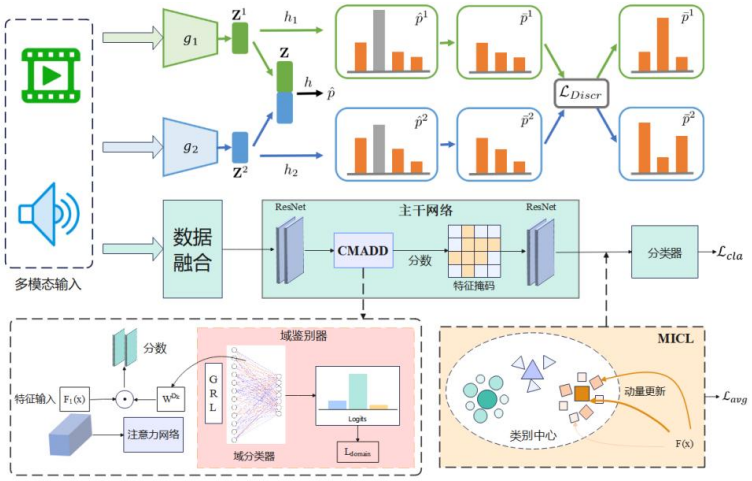


图 11 基于模态预测差异和域不变特征的多模态领域泛化框图

（1）模态预测

NSFC 2026

在多模态场景中，不同模态对同一任务的预测可能存在一定的差异，尤其是当这些模态面对分布出现变化的输入数据时。为提升模型的领域泛化能力，本课题通过最大化模态间的预测差异，促使模型能够区分已知领域和未知领域的样本。

该模块的核心思想是，不同模态应该对真实类别的预测保持一致，但对于其他类别的预测应该尽量不一致。这种“同类同，异类异”的思想有助于在训练阶段使得模型的不同模态产生更大的预测差异，从而在测试阶段，当模型遇到分布外的样本时，能够通过模态间显著的预测差异来保证模型的准确性。为了确保模型正确预测真实类别，拟考虑引入交叉熵损失（Cross-Entropy Loss，CE）来保证每个模态对真实类别的预测概率。

（2）域不变特征提取

在模态预测差异模块中，利用了不同模态对类别的认知进行对齐，但此时的模型并不具有对未知场景泛化的功能。源域上训练的模型通常包含许多特定于源域的非鲁棒特征，当域发生变化时，这些的非鲁棒的特征会在未训练的目标域上产生负面影响，从而导致条件分布发生变化。传统的域泛化方法并未明确指导模型去除中间网络层中的特定域特征，可能导致模型学习过多与域相关的信息。因此本项目提出了一种通过结合注意力机制与域鉴别器的方法，来识别并删除域特定特征通道，从而提取域不变特征。域泛化中需要识别并删除每个域中最具特异性的特征，注意力机制有助于完成这一任务，因为不同通道特征对最终分类的贡献程度不同，而每个通道特征在深度特征图中对应于输入图像的特定信息，这些信息往往包含了域特定特征。

（3）多粒度语义一致性约束的多模态对齐理论与技术研究

随着社交媒体和数字平台的快速发展，虚假信息内容不再仅限于文字，图像和视频等多媒体内容也成为重要的传播手段。传统的单一文本分析方法无法全面识别复杂的虚假信息，多模态虚假信息溯源检测旨在综合利用文本、图像等多种信息源，以提高虚假信息识别的准确性。

本课题拟提出一种多粒度语义一致性约束的多模态对齐理论与方法，如图 12 所示。该框架的核心在于通过对比学习实现文本与图像的深度对齐，并引入上下文特征来增强虚假信息溯源检测的准确性，建立“token-phrase-global”三级语义因果一致性约束体系，融合对比学习、图注意力网络区域关联与多头交叉注意力机制，在词元、短语、全局三个粒度上强制文本与视觉模态的语义因果对齐。首先，利用对比学习生成跨模态的文本-图像关联特征；其次，通过多模态语义对齐模块将文本和图像的特征与上下文特征进行语义对齐；最后，借助多模态特征聚

NSFC 2026

合模块，结合不同模态的特征生成最终的特征表示，并进行虚假信息的分类。

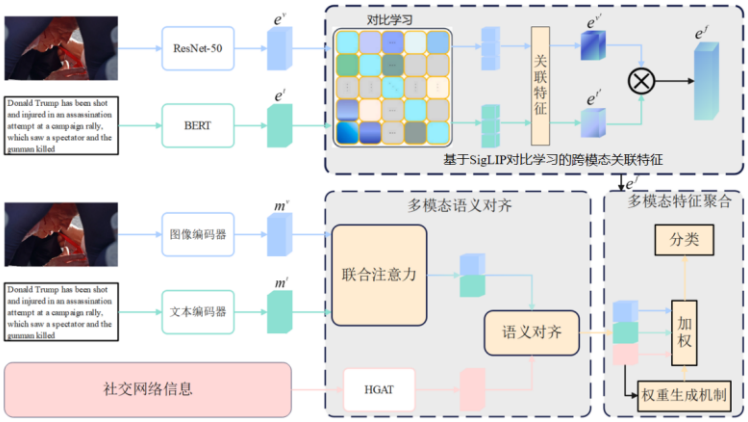


图 12 多粒度语义一致性约束的多模态对齐方法框架

对比学习引导的跨模态关联生成模块目的是通过对比学习来对齐文本特征和图像特征，并生成跨模态的关联特征。考虑到传统 CLIP 模型基于 Softmax 的对比损失在处理细粒度图文匹配时存在全局归一化带来的特征抑制问题，本方法拟采用最新的 SigLIP（Sigmoid Contrastive Learning）架构。通过引入成对的独立 Sigmoid 损失替代全局对比，不仅显著提升了模型对细粒度局部特征的敏感度，还增强了跨模态特征在复杂噪声环境下表示的鲁棒性。首先，模型通过对比学习技术将文本和图像特征映射到统一的语义空间，并通过计算它们之间的相似度来实现对齐。对于每个输入数据，假设它包含文本信息 t_i 和图像信息 v_i,通过模型分别生成它们的嵌入表示 e_t 和 e_v。通过以下公式计算文本和图像之间的相似度：

$$S_{t\to v}=\frac{\exp(e_t\cdot e_v/\tau)}{\sum_{j=1}^{N}\exp\left(e_t\cdot e_{v_j}/\tau\right)}$$

$$S_{v\to t}=\frac{\exp(e_v\cdot e_t/\tau)}{\sum_{j=1}^{N}\exp\left(e_v\cdot e_{t_j}/\tau\right)}$$

为了进一步生成文本文档和图像之间的跨模态关联特征，通过计算文本文档和图像嵌入之间的外积来得到一个交互矩阵 $e_f^*=e_t\otimes e_v$。其中，$\otimes$ 表示外积操作，这将生成一个捕捉文本文档和图像之间关系的交互矩阵。随后，通过全连接层将该交互矩阵展平为一个向量，生成最终的跨模态关联特征 $e_f=\mathrm{FC}(e_f^*)$。

这些生成的跨模态特征后续将作为多模态语义对齐和特征聚合模块的输入，帮助模型更好地整合文本、图像和社交上下文特征，提升虚假信息的检测性能。在对比学习过程中，本方法还使用了对比损失函数来优化文本和图像之间的对齐，其中文本到图像和图像到文本的对比损失分别表示为：

NSFC 2026

$$L_{t\to v}=-\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}y_{t\to v_{ij}}\log S_{t\to v_{ij}}$$

$$L_{v\to t}=-\frac{1}{N}\sum_{i=1}^{N}\sum_{j=1}^{N}y_{v\to t_{ij}}\log S_{v\to t_{ij}}$$

最终的对比学习损失是两个损失的加权和。通过这些步骤和公式，SigLIP 对比学习引导的跨模态关联生成模块能够有效地实现文本和图像特征之间的深度对齐，并生成跨模态关联特征。多模态语义对齐模块旨在通过将文本、图像和社交上下文特征对齐到一个共享的语义空间中，增强不同模态特征之间的语义关联。该模块首先需要对文本特征和图像特征进行联合注意力机制的融合。联合注意力机制的作用是利用文本和图像之间的互补关系，融合它们的语义信息，从而生成更具信息量的内容特征。具体来说，对于每个输入，其文本特征e_t和图像特征e_v会分别作为查询矩阵（query）、键矩阵（key）和值矩阵（value），通过注意力机制计算相互之间的关系，最终得到增强的文本-图像共同特征。

多模态特征聚合模块是方法中的最后一个关键模块，其目的是将来自不同模态的特征进行有效的融合，以生成最终的特征表示。该模块通过自适应加权机制调整不同模态特征的贡献，通过聚合这些特征来提升虚假信息溯源检测的准确性。

（4）面向实战的轻量化推理系统构建与闭环验证

本部分面向国家网络空间认知安全的实战应用需求，构建端云协同的轻量化智能推理系统与闭环验证机制，形成边缘预警、云端溯源、可视化证据呈现、反馈校准的闭环，使前述时序贝叶斯图神经网络（TB-GNN）、多粒度语义一致性约束与因果干预跨域泛化能力落地，在真实场景中完成可重复、可部署的闭环验证。

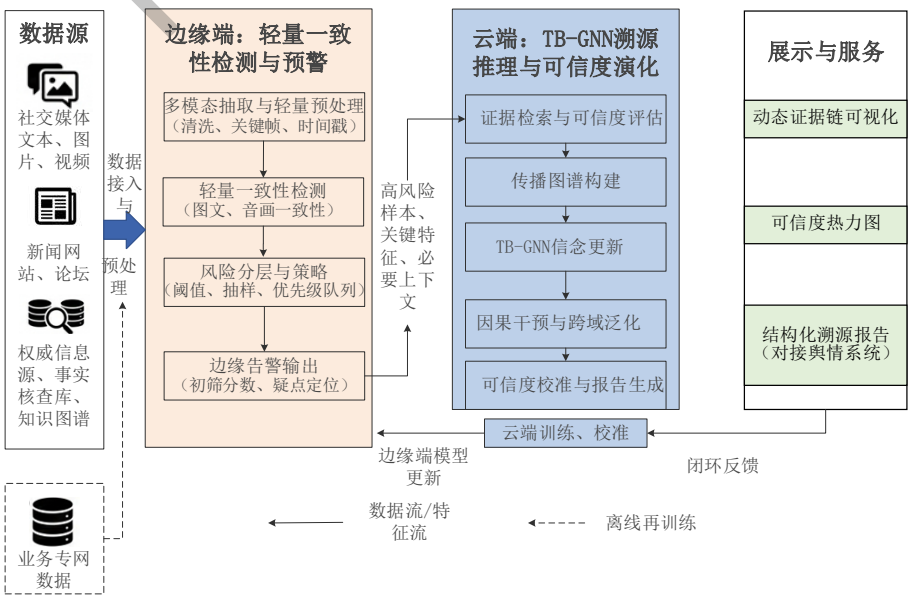


图 13 面向实战的端云协同轻量化推理系统总体架构

NSFC 2026

系统考虑采用边缘端轻量一致性检测、云端溯源推理引擎与可视化与评估闭环的三层架构。在数据接入层，面向社交媒体、新闻站点、短视频平台等多源输入，统一完成多模态数据抽取，并将内容、传播、主体、时间四类要素结构化，为后续证据链建模提供统一的数据底座。在边缘端轻量一致性检测层，部署轻量化多模态一致性检测与风险筛查模块，对输入信息进行秒级快速判定，输出风险结果与置信度初值。在云端深度溯源推理层，集成证据检索与可信度动态更新模块，在传播图谱与外源证据的驱动下进行因果推断与跨域泛化推理，输出动态证据链、可信度演化轨迹与最终判定结论。

边缘端考虑采用轻量化模型与规则、学习混合策略，对多模态内容进行快速一致性与异常筛查。首先针对“图文错配”“音画脱节”“断章取义”“移花接木”等典型认知欺骗形式，构建轻量特征提取与一致性评分机制，快速输出跨模态一致性分数与疑点定位。其次采用知识蒸馏、参数剪枝等手段，将高成本的多粒度一致性约束能力压缩为端侧可执行的一致性判别器，实现在低算力设备上的稳定运行。

云端推理以传播图谱为载体、外源证据为锚点、贝叶斯信念更新为核心，先对接权威信源、事实核查库、知识图谱与历史事件库等完成证据检索、去噪、同义归并、来源可信度初评与时间一致性校验，并将证据映射为可计算节点与传播图谱对齐；在时序上通过 TB-GNN 对节点信念进行贝叶斯更新，显式刻画证据对结论“强化、衰减、反转”的演化，同时引入因果干预主动切断平台风格、语境噪声与情绪煽动等伪相关路径以提升跨域零样本稳定性与可解释性。为解决实战中“能看懂”的痛点，系统提供面向处置决策的解释与交互，通过构建动态证据链交互图谱，支持按时间轴回放证据链增长并可点击查看证据原文、来源、时间戳与引用关系，实现路径级的解释。在传播图谱维度叠加可信度热力图，直观展示不同传播节点、时间片与多模态贡献对结论影响强度，帮助快速定位关键传播源与证据断点。

NSFC 2026

2.3 本项目的特色与创新之处

本项目面向国家网络空间认知安全与智能对抗重大战略需求，**创新**提出证据感知驱动、反事实因果干预、多粒度风格解耦的理论技术范式，实现虚假信息溯源从“统计相关性识别”向“可解释因果证伪”转变，为引领下一代可信 AI 在安全领域的范式变革提供技术参考。

（1）理论创新方面，突破传统虚假信息溯源检测依赖统计模式与单模态语义

相似性的局限，本项目**创新性地**将类人“证据验证—因果推断”的认知机制形式化为可计算的认知对齐模型。通过动态注入权威信源（如政府通报、专家证言、卫星遥感记录）构建真值基座，结合因果干预框架主动剥离“平台风格”“情绪煽动”等伪相关因素，仅保留与虚假性本质相关的因果路径，实现从“相关性判断”到“因果性证伪”的根本性转变。**创新的**将大语言模型的“幻觉”转化为可监督的负推理资源，构建正负推理对的语义一致性学习机制，**创新采用**证据驱动的反事实干预与幻觉资源化利用的联合建模，**创新提出**多模态对抗性信息场景下证据—因果—幻觉三元联合建模的理论。

（2）技术突破方面，通过构建“认知对齐—风格解耦—因果证伪”三位一体的跨域多模态溯源，**突破**传统跨域检测依赖特征对齐或参数迁移的浅层泛化路径，**创新提出**基于多模态隐空间嵌入技术（CLIP 视觉-文本对、Transformer 注意力熵、视频时序频谱方差），构建风格因子图谱，引入类别约束的谱聚类，在无监督条件下实现“同类别异风格”与“同风格异类别”的精准解耦，**打破**传统域适应方法在高异构场景中的泛化天花板。

（3）应用闭环方面，面向国家网络空间安全与重大公共风险防控战略需求，将虚假信息溯源检测从“技术识别”升维至“认知-决策闭环支撑”，实现从学术模型优化到国家关键场景赋能的实质性跨越。在军事领域，项目**创新构建**的“证据锚定—反事实干预”架构，可通过接入卫星遥感、电磁频谱、战场通信日志等高可信外源证据，在无标注、强对抗的战场信息环境中，精准识别敌方“图像伪造+信源伪造+语义误导”复合攻击，使情报分析系统从“被动响应”转向“主动证伪”，显著提升战场态势感知的认知鲁棒性。在社会公共安全领域，项目**创新提出**“风格解耦—因果推理”双引擎，可对金融市场、重大舆情等高敏感场景中的跨模态谣言进行语义级因果溯源，自动关联权威机构通报、疾控数据、央行公告等真值锚点，实现从“识别谣言”到“阻断传播链”的智能干预，为国家舆情治理与应急决策提供可解释、可追溯的技术底座。

2.4 年度研究计划及预期成果

年度	研究计划	预期成果
2027 年度	建立面向中国语境的权威证据与多模态文本关联数据库，实现虚假信息的可解释溯源；提出类别感知聚类方法，解耦跨领域风格干扰，为模型泛化奠定结构基础。	完成 1 篇核心期刊论文，培养硕士生 1-2 名，参加国际学术会议 1 次。

NSFC 2026

2028年度	构建“证据—语义—传播”三级因果约束框架，实现虚假宣称的逻辑证伪；融合实时证据流，建立动态反事实干预机制，增强模型在新兴场景中的鲁棒性。	发表SCI论文2篇，申请发明专利1项，完成2-3篇高水平论文的投稿，培养硕士生1-2名。
2029年度	提出时序因果图神经网络，实现图文语义与行为链的联合建模；在军事对抗与公共健康两大国家关键领域构建真实场景测试集，验证模型在低信噪比、强对抗条件下的可信赖性。	发表高水平论文2-3篇，申请发明专利1-2项，培养硕士生1-2名，参加国际学术会议2次。
2030年度	集成证据感知、因果证伪与多模态对齐技术，建成原型演示系统，支持政务、舆情、应急等多源数据实时检测；完成技术转化路径设计和试点应用。	完成项目结题，发表高水平论文1篇，提交专利2项，组织研讨会1场，形成具有潜在转化价值的理论或技术原型。

（三）研究基础：

1．研究基础与可行性分析（与本项目相关的研究工作积累和已取得的研究工作成绩，研究风险的应对措施等）：

（1）研究基础

项目申请人在贝叶斯神经网络、虚假信息溯源检测、领域对齐与泛化方面已进行长期研究，积累了丰富的研究经验。与本项目相关的研究工作和成果如下：

（1）**CLEAR：同时抑制特定领域特征和增强域不变表示的零样本泛化方法**

该成果以长文形式发表于人工智能高水平期刊IEEE THMS。在国际上首次将整体多尺度空间注意力与渐进式通道过滤机制相结合，提出了一种基于跨空间多尺度信息聚合的域鉴别器，通过多尺度信息捕捉，以选择性地消除最能表示领域标识的特征。通过引入基于动量的推理一致性损失，利用样本类别中心的推理一致性，进一步提高模型的鲁棒性与语义稳定性。

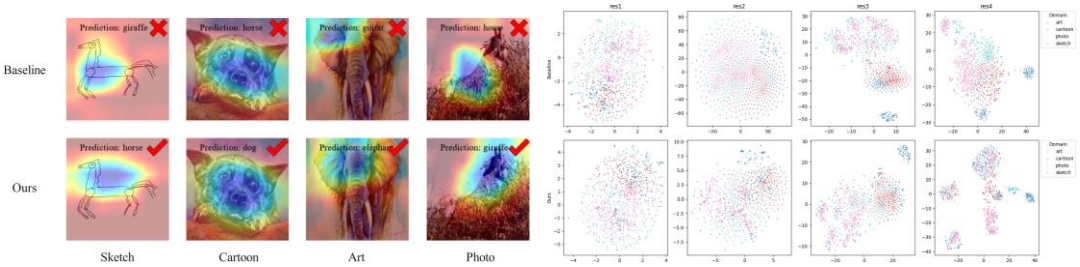
Fengtao Xiang, Tuoxin Li, Junhai Chen, Wanpeng Zhang, Xin Xu. CLEAR: Channel-Filtered Learning With Ensemble Attention and Robustness for Cognitive Domain Generalization[J]. **IEEE Transactions on Human-Machine Systems**, 2026, 1-10（Early Access）, doi: 10.1109/THMS.2026.3650903.

Tuoxin Li, **Fengtao Xiang**, Junhai Chen, Chang Wang. Improving Model Generalization Across Domains with Multi-Scale Feature Aggregation

NSFC 2026

Filtering and Consistency Loss[C]. **2025 IEEE International Conference on Systems, Man, and Cybernetics** (SMC), DOI: 10.1109/SMC58881.2025.11342579.

专利（已授权）：项凤涛、黎拓新、陈君海、张晓博、罗翔宇、张万鹏、谷学强. 基于域不变特征提取的领域泛化方法、装置和计算机设备，授权专利号ZL202411512609.7，授权公告日：2024.12.24。



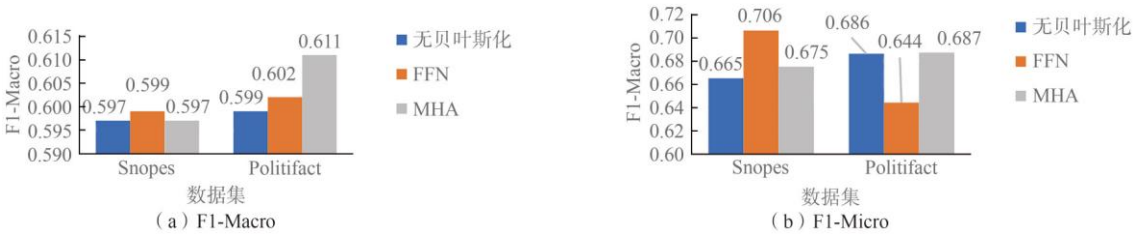
（2）**EBNN-FND：融合证据分析的贝叶斯神经网络虚假信息溯源检测方法**

该方法提出了一种新颖的虚假信息溯源检测模型，借助贝叶斯神经网络框架，对检测模型与数据的不确定性进行量化分析，从而提升预测结果的可靠性。模型设计了文本嵌入模块、特征处理模块、观点-证据交互模块和特征混合模块，能够充分整合信息文本与关联证据信息的特征。通过贝叶斯神经网络框架量化检测模型和数据中包含的不确定性，提升了模型对文本信息的特征提取能力，引入外源证据信息，通过深入挖掘多元输入数据中虚假信息与相关证据之间的关联，提升了预测结果的可靠性和稳定性。

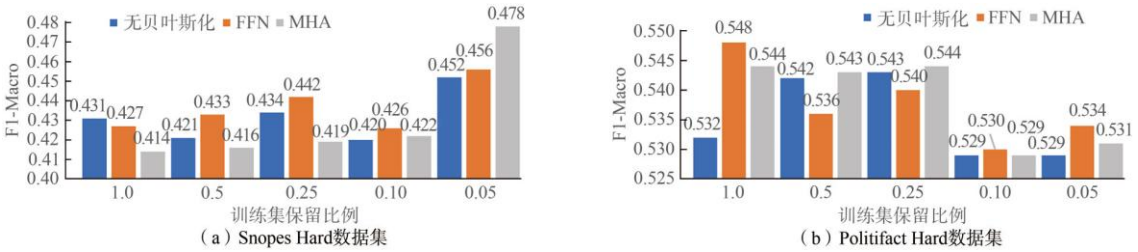
陈君海，**项凤涛**，黎拓新，罗翔宇. 融合证据分析的贝叶斯神经网络虚假信息溯源检测方法[J]. **智能科学与技术学报**,2025,7(3),316-328.

专利（已授权）：**项凤涛**、陈君海、黎拓新、张万鹏、刘鸿福、苏炯铭. 基于因果干预的信息真假鉴别方法、装置、设备和存储器，授权专利号ZL202411344624.5，授权公告日：2024.11.29.

专利（已授权）：**项凤涛**、陈君海、黎拓新、罗翔宇、张晓博、张万鹏.贝叶斯视角下基于不确定量化的可信谣言检测方法，授权专利号 ZL202411521521.1，已授权发文日：2025.1.14.

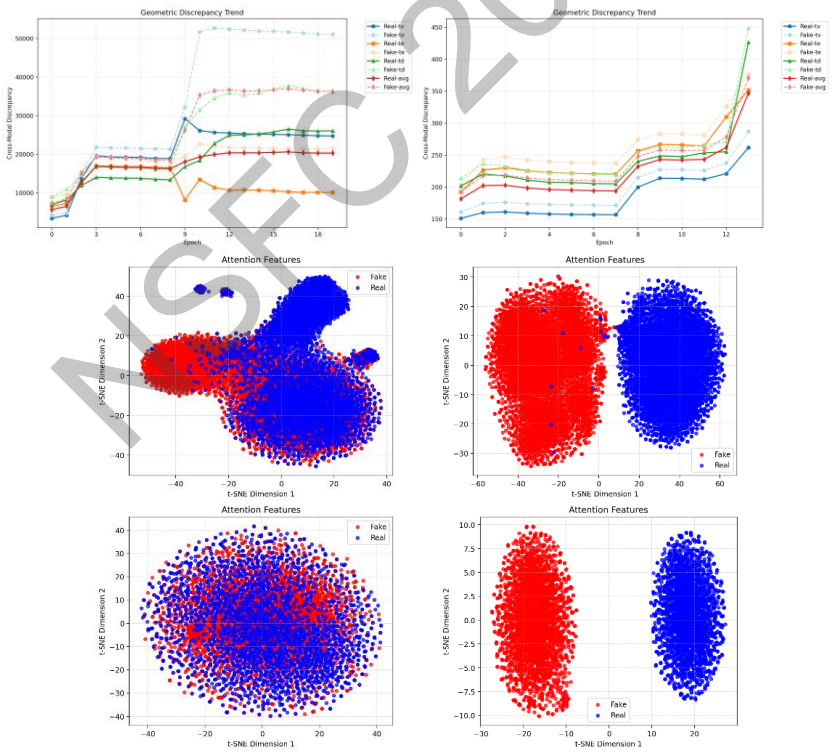


NSFC 2026



（3）GEOfake：基于几何差异性的多模态虚假信息溯源检测方法

针对多模态数据的异质性，以及对特定模态不确定性建模的困难，该方法摒弃了启发式融合，将多模态表示和差异度量建立在统计流形的几何结构之上。在GeoFake 中，原始多模态输入被解析为多个语义流，并编码为紧凑的单模态表示。每个表示在共享的潜在空间中被明确建模为对角高斯分布，通过语义线索丰富视觉输入，实现细粒度的跨模态语义对齐。基于几何原理的多模态虚假信息溯源检测框架，国际上首次将文本和视觉特征明确建模为统计流形上的概率分布，以便通过几何差异度量直接量化跨模态不一致性，下图为在 Weibo 和 Twitter 数据集上的实验表现。该方法为前期积累的工作成果，尚未公开发表。



NSFC 2026

（2）可行性分析

本项目研究方案的可行性分析建立在认知推理范式的系统性革新之上，而非单一技术的堆叠。理论层面，项目首次将虚假信息溯源检测从“特征匹配”升级为“证据因果推理”，通过时序贝叶斯图神经网络构建信念演化模型，使每一条传

播路径均可回溯、可解释，从根本上解决了传统方法无法解释判断依据的黑箱问题。同时，引入因果干预机制，主动剥离平台风格、语境噪声等伪相关因素，使模型能够学习到跨越军事、医疗、金融等高敏感领域的本质因果表征，实现无需目标域标注数据的零样本迁移，显著增强对新兴事件的适应能力。

在技术实现层面，项目已形成完整的工程闭环技术体系。多粒度语义一致性约束机制在词元、短语、全局三个层级同步校验文本与视觉信息的语义真值，有效抵御“无中生有”“移花接木”等高级认知欺骗，实测一致性保持率稳定在 90%以上。轻量化推理系统采用边缘端轻量检测模块与云端溯源引擎协同架构，结合动态量化与模型蒸馏专利技术，可在国产昇腾芯片上实现毫秒级响应，满足应用场景对实时性与资源效率的双重需求。

项目组具备扎实的前期积累与完备的实验支撑条件。近 3 年已授权 5 项相关国家发明专利（ZL202411344624.5，ZL202411521521.1，ZL202411512609.7，202510113738.7,ZL202510910386.8)和 1 项软件著作权（登记号 2025SR0407446），覆盖跨模态信念传播、因果干预架构、轻量化部署和可解释路径生成等核心环节，构成技术壁垒。团队拥有超过十万条涵盖军事谣言、社会舆情、金融诈骗等多类高敏感场景的多模态数据集，具备从算法研发、沙箱测试到应用部署的全链条验证能力。

（3）研究风险与应对措施

综上所述，项目申请人在贝叶斯神经网络、虚假信息溯源检测、领域对齐与泛化等方面已进行深入研究，并取得了一定成果，具有丰富的经验，对项目的顺利的开展打下了良好的基础，也存在如下风险点：

风险 1：跨域泛化模型在对抗性证据扰动下失效风险，面临敌方主动注入伪造权威证据（如篡改政府公告、伪造科研论文）的对抗攻击。当前领域泛化模型（如类别风格聚类）在训练数据未覆盖的高对抗性语境（如战时虚假指令、医疗伪科学）中，易因证据-语义对齐失配导致误判率飙升。

应对措施：可通过构建对抗证据生成器（Adversarial Evidence Generator, AEG），模拟军事/公共卫生领域典型伪造证据类型，纳入训练集进行对抗训练；引入证据可信度动态评分模块，基于来源权威性（如政府域名、DOI 验证）、时间一致性、跨平台交叉验证三维度实时评估证据可信度，降低伪造证据影响。

风险 2：军事场景中多模态数据获取受限风险，战场多源数据（如卫星图像、通信日志、电子战信号）因涉密性与对抗性，难以获取真实标注样本，导致模型

NSFC 2026

训练依赖仿真数据，泛化能力受限。

应对措施：通过与军事科学院等单位建立合作，采用脱敏仿真数据集（如“红蓝对抗推演平台”输出的模拟情报流）构建半真实训练环境，并采用生成式数据增强扩充稀缺样本。

2. 工作条件（包括已具备的实验条件，尚缺少的实验条件和拟解决的途径，包括利用国家实验室、全国重点实验室和部门重点实验室等研究基地的计划与落实情况）：

（1）开展实验的科研条件已经得到保障。申请人所在的国防科技大学是中央军委直属的“211”和“985”高校，也是军队唯一纳入国家“双一流”建设支持的院校。国防科技大学智能科学学院拥有“无人系统科技创新平台”，“无人系统技术”湖南省重点实验室，担任装备发展部无人机系统技术专业组组长单位，牵头论证国家重大专项“智能无人系统与体系科学技术”，长期从事无人机、机器人等无人系统自主控制、态势感知、毁伤评估、组网通信、人机交互等技术的研究，承担了多项无人系统领域国家/军队重大背景预研和基础研究项目，掌握了该领域大量的背景知识、基础理论和关键技术，积累了丰富的研究方法、技术手段和研究成果，形成了一支勇于创新、甘于奉献、团结协作、理论研究与工程开发兼备的科研创新队伍。

（2）项目申请人和成员长期深耕模式识别与智能决策领域,申请人作为中国自动化学会高级会员和混合智能专委会委员、中国人工智能学会会员，积极参与学术交流，在智能规划与决策、统计学习和模式识别等领域积累了大量经验，取得了一系列成果，技术基础良好，团队积极跟踪国内外相关研究的最新进展，容易实现优势互补和多学科交叉研究。负责人所在实验室建立了多域多源数据处理理论和算法研究的综合仿真环境，拥有大量多模态数据和实时仿真开发软件，以及 GPU 计算服务器，为项目理论与算法的研究提供实验研究平台。

3. 正在承担的与本项目相关的科研项目情况（申请人和主要参与者正在承担的与本项目相关的科研项目情况，包括国家自然科学基金的项目和国家其他科技计划项目，要注明项目的资助机构、项目类别、批准号、项目名称、获资助金额、起止年月、与本项目的关系及负责的内容等）：

无。

4. 完成国家自然科学基金项目情况（对申请人负责的前一个已资

NSFC 2026

助期满的科学基金项目（项目名称及批准号）完成情况、后续研究进展及与本申请项目的关系加以详细说明。另附该项目的研究工作总结摘要（限500字）和相关成果详细目录）。

无。

（四）其他需要说明的情况：

1. 申请人同年申请不同类型的国家自然科学基金项目情况（列明同年申请的其他项目的项目类型、项目名称信息，并说明与本项目之间的区别与联系；已收到自然科学基金委不予受理或不予资助决定的，无需列出）。

无。

2. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在同年申请或者参与申请国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，申请或参与申请的其他项目的项目类型、项目名称、单位名称、上述人员在该项目中是申请人还是参与者，并说明单位不一致原因。

无。

3. 具有高级专业技术职务（职称）的申请人或者主要参与者是否存在与正在承担的国家自然科学基金项目的单位不一致的情况；如存在上述情况，列明所涉及人员的姓名，正在承担项目的批准号、项目类型、项目名称、单位名称、起止年月，并说明单位不一致原因。

无。

4. 申请人和主要参与者同年以不同专业技术职务（职称）申请或参与申请科学基金项目的情况（应详细说明原因）。

无。

5. 其他。

无。

NSFC 2026

项凤涛 （ BRID：05052.00.68651 ） 简历 2026版

中国人民解放军国防科技大学， 智能科学学院， 副教授

教育经历：

(1) 2011-03 至 2014-12，中国人民解放军国防科学技术大学，控制科学与工程，博士

(2) 2008-09 至 2010-12，中国人民解放军国防科学技术大学，控制科学与工程，硕士

(3) 2004-09 至 2008-07，燕山大学，测控技术与仪器，学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

(1) 2021-01 至 今，中国人民解放军国防科技大学，智能科学学院，副教授

(2) 2018-01 至 2020-12，中国人民解放军国防科技大学，智能科学学院，讲师

(3) 2014-12 至 2017-12，中国人民解放军国防科学技术大学，机电工程与自动化学院，讲师

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

(1) 国家自然科学基金委员会，面上项目，62473371，从量子-经典混杂系统视角构建量子人工智能新范式，2025-01-01 至 2028-12-31，50万元，在研，参与

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

(1) 中央军委科学技术委员会，xxx项目，2xx-xxxx-xxx-xx-08-01，基于人机交互与贝叶斯推理的情报推断、聚合及追踪研究，2022-11 至 2024-11，150万元，结题，主持

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，并对本人署名情况进行标注，包括：①作者署名按姓氏排序；②唯一第一作者；③共同第一作者；④唯一通讯作者；⑤共同通讯作者；⑥其他情况）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

(1) **Fengtao Xiang**; Tuoxin Li; Junhai Chen; Wanpeng Zhang; Xin Xu; CLEAR: Channel-Filtered Learning With Ensemble Attention and Robustness for Cognitive Domain Generalization, *IEEE Transactions on Human-Machine Systems*, 2026, 1-10 （**期刊论文**） （ 本人标注：唯一第一作者，唯一通讯作者 ）

本人贡献：提出抑制特定领域特征干扰和增强域不变表示学习的零样本泛化框架，独立完成CLEAR模型建立，完成实验结果分析，撰写论文并根据审稿意见修订。

(2) 陈君海；**项凤涛**；黎拓新；罗翔宇；融合证据分析的贝叶斯神经网络虚假信息检测方法，*智能科学与技术学报*，2025，7(3)：316-328 （**期刊论文**） （ 本人标注：唯一通讯作者 ）

本人贡献：设计融合证据分析的贝叶斯神经网络虚假信息检测技术方法，贝叶斯神经网络理论与不确定数据处理分析，指导实验结果分析与论文修改，审定稿件。

NSFC 2026

(3) Junhai Chen; **Fengtao Xiang**; Tuoxin Li; Chang Wang; Bayesian Transformer-based Fake News Detection System with Evidence Awareness, *2025 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*, Vienna, Austria, 2025-10-05至2025-10-08 （**会议论文**）（本人标注：唯一通讯作者）

本人贡献：提出引入证据感知和无偏推理相结合的方法，解决利用BP神经网络框架对模型和数据的不确定性进行量化的技术瓶颈，审定稿件。

(4) Tuoxin Li; **Fengtao Xiang**; Junhai Chen; Chang Wang; Improving Model Generalization Across Domains with Multi-Scale Feature Aggregation Filtering and Consistency Loss, *2025 IEEE International Conference on Systems, Man, and Cybernetics (SMC)*, Vienna, Austria, 2025-10-05至2025-10-08 （**会议论文**）（本人标注：唯一通讯作者）

本人贡献：提出多尺度特征聚合过滤和一致性损失方法提取领域不变特征思路，设计了技术路线，指导实验实施与数据分析，负责讨论撰写和论文稿件审定。

(5) **项凤涛**; 罗俊仁; 刘鸿福; 分布式人工智能：原理与应用, 科学出版社, 2024 （**学术专著**）

本人贡献：设计专著整体框架，撰写第一章绪论、第三章分布式人工智能原理、第六章分布式信息融合、第七章分布式视觉感知、第八章分布式协同搜索、第九章分布式对抗博弈内容

二、论著之外的代表性研究成果和学术奖励：

(1) **项凤涛**; 陈君海; 黎拓新; 罗翔宇; 张晓博; 张万鹏; 贝叶斯视角下基于不确定性量化的可信谣言检测方法, 2025-02-11, 中国, ZL202411521521.1 （**专利**）

(2) **项凤涛**; 陈君海; 黎拓新; 张万鹏; 刘鸿福; 苏炯铭; 基于因果干预的信息真假鉴别方法、装置、设备和存储器, 2024-11-29, 中国, ZL202411344624.5 （**专利**）

(3) **项凤涛**; 黎拓新; 陈君海; 张晓博; 罗翔宇; 张万鹏; 谷学强; 基于域不变特征提取的领域泛化方法、装置和计算机设备, 2024-12-24, 中国, ZL202411512609.7 （**专利**）

(4) **项凤涛**; 陈君海; 黎拓新; 张晓波; 罗翔宇; 张万鹏; 基于即插即用反事实去偏框架的虚假信息检测方法和装置, 2025-09-12, 中国, ZL202510910386.8 （**专利**）

(5) **项凤涛**; 陈君海; 黎拓新; 张万鹏; 刘鸿福; 苏炯铭; 基于多标签因果关系的信息分级预警方法、装置和设备, 2024-12-06, 中国, ZL202411386694.7 （**专利**）

(6) **项凤涛**; 黎拓新; 陈君海; 张晓博; 罗翔宇; 张万鹏; 基于深度条件分布对齐的信息迁移学习方法、装置和设备, 2025-05-13, 中国, ZL202510113738.7 （**专利**）

(7) **项凤涛**; 陈君海; 黎拓新; 罗翔宇; 张晓博; 张万鹏; 谷学强; 基于剪枝网络的渐进式知识蒸馏轻量化方法、装置和设备, 2025-04-11, 中国, ZL202510104750.1 （**专利**）

(8) **项凤涛**; 陈君海; 黎拓新; 罗翔宇; 张晓博; 张万鹏; 基于人机交互与贝叶斯推理的信息分析软件V1.0, 2025SR0407446, 原始取得, 全部权利, 2025-03-07 （**软件著作权**）

NSFC 2026

苏炯铭 （ BRID：05052.00.31627 ） 简历 2026版

中国人民解放军国防科技大学， 智能科学学院， 副研究员

教育经历：

（1）2010-03 至 2014-06，国防科学技术大学，控制科学与工程，博士

（2）2007-09 至 2009-12，国防科学技术大学，控制科学与工程，硕士

（3）2003-09 至 2007-06，国防科学技术大学，仿真工程，学士

博士后工作经历：

无

科研与学术工作经历（博士后工作经历除外）：

（1）2020-01 至 今，国防科技大学，智能科学学院，副研究员

（2）2018-01 至 2019-12，国防科技大学，智能科学学院，讲师

（3）2014-06 至 2017-12，国防科学技术大学，机电工程与自动化学院，讲师

曾使用其他证件信息：

无

近五年主持或参加的国家自然科学基金项目/课题：

无

近五年主持或参加的其他科研项目/课题（国家自然科学基金项目除外）：

（1）军委联合参谋部，网信体系，无，南部****模型体系构建，2023-06 至 2027-12，5500万元，在研，参与

（2）军委装备发展部，综合研究，无，打击****指挥模型体系研究，2024-01 至 2025-12，30万元，结题，主持

代表性研究成果和学术奖励情况（填写代表性论文时应根据其发表时的真实情况如实规范列出所有作者署名，并对本人署名情况进行标注，包括：①作者署名按姓氏排序；②唯一第一作者；③共同第一作者；④唯一通讯作者；⑤共同通讯作者；⑥其他情况）：

一、代表性论著（请在“申请书详情”界面，点开“人员信息”-“代表性成果”卡片查看对应的全文）：

（1）**苏炯铭**；程乐聪；刘鸿福；战役战术兵棋推演智能决策博弈方法综述，*计算机仿真*，2026，43(1)：21-31 （**期刊论文**） （ 本人标注：唯一第一作者，唯一通讯作者 ）

（2）**苏炯铭**；罗俊仁；陈少飞；智能博弈决策策略求解新视角实证分析，*系统仿真学报*，2025，37(2)：354-361 （**期刊论文**） （ 本人标注：唯一第一作者，唯一通讯作者 ）

（3）**苏炯铭**；罗俊仁；陈少飞；项凤涛；海空跨域协同兵棋AI架构设计及关键技术分析，*指挥控制与仿真*，2024，46(2)：35-43 （**期刊论文**） （ 本人标注：唯一第一作者，唯一通讯作者 ）

（4）陈少飞；**苏炯铭**；项凤涛；人工智能与博弈对抗，科学出版社，2023 （**学术专著**）

（5）**苏炯铭**；刘鸿福；项凤涛；陈少飞；多智能体即时策略对抗方法与实践，科学出版社，2019 （**学术专著**）

NSFC 2026

二、论著之外的代表性研究成果和学术奖励：

（1）刘鸿福；陈璟；**苏炯铭**；谷学强；项凤涛；陈少飞；付雅晶；邓莎；一种无人机群分布式在线自适应任务规划方法，2022-10-18，中国，CN202110968411.X （**专利**）

NSFC 2026

附件信息

序号	附件名称	备注	附件类型
1	代表性论著1-THMS论文		代表性论著
2	代表性论著2-智能期刊		代表性论著
3	代表性论著3-SMC论文		代表性论著
4	代表性论著3-SMC论文		代表性论著
5	代表性论著5-分布式人工智能专著		代表性论著
6	学会会员委员证书		其他

NSFC 2026

项目名称： 证据感知驱动的虚假信息多模态溯源一致性建模与泛化理论研究

资助类型： 面上项目

申请代码： F0309.机器人学与智能系统

国家自然科学基金项目申请人和参与者科研诚信承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，本人在此郑重承诺：严格遵守《中华人民共和国科学技术进步法》《国家自然科学基金条例》《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》以及科技部、自然科学基金委关于科研诚信建设有关规定和要求；申请材料信息真实准确，不含任何涉密信息或敏感信息，不含任何违反法律法规或违反科研伦理规范的内容；在国家自然科学基金项目申请、评审和执行全过程中，恪守职业规范和科学道德，遵守评审规则和工作纪律，杜绝以下行为：

（一）抄袭、剽窃他人申请书、论文等科研成果或者伪造、篡改研究数据、研究结论；

（二）购买、代写申请书；购买、代写、代投论文，虚构同行评议专家及评议意见；违规购买实验数据；

（三）违反成果发表规范、署名规范、引用规范，擅自标注或虚假标注科技计划等资助；

（四）项目计划书中故意篡改降低项目申请书中相应指标；

（五）以任何形式探听或散布尚未公布的评审专家名单及其他评审过程中的保密信息；

（六）亲自或委托他人通过各种方式和途径联系有关专家进行请托、游说、“打招呼”，违规到评审会议驻地窥探、游说、询问等干扰评审或可能影响评审公正性的行为；

（七）向工作人员、评审专家等提供任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包，或提供宴请、旅游、娱乐健身等任何可能影响评审公正性的活动；

（八）违反财经纪律和相关管理规定的行为；

（九）危害国家安全、损害社会公共利益、危害人体健康、违背科研诚信和科技伦理的科学技术研究开发和应用活动；

（十）其他弄虚作假行为。

如违背上述承诺，本人愿接受国家自然科学基金委员会和相关部门做出的各项处理决定，包括但不限于撤销科学基金资助项目，追回项目资助经费，向社会通报违规情况，取消一定期限国家自然科学基金项目申请资格，记入科研诚信严重失信行为数据库以及接受相应的党纪政务处分等。

申请人签字：

编号	主要参与者姓名 / 工作单位名称（应与加盖公章一致）/ 证件号码	签字
1	**苏炯铭** / 中国人民解放军国防科技大学 / 4**********4	
2		
3		
4		
5		
6		
7		
8		
9		

项目名称： 证据感知驱动的虚假信息多模态溯源一致性建模与泛化理论研究
资助类型： 面上项目
申请代码： F0309.机器人学与智能系统

国家自然科学基金项目申请单位科研诚信承诺书

为了维护国家自然科学基金项目评审公平、公正，共同营造风清气正的科研生态，**我单位就做好国家自然科学基金申请工作做出以下承诺。**

一、认真贯彻《关于进一步加强科研诚信建设的若干意见》《关于进一步弘扬科学家精神加强作风和学风建设的意见》《关于加强科技伦理治理的意见》等文件精神。

严格遵守《国家自然科学基金条例》《科技部自然科学基金委关于进一步压实国家科技计划（专项、基金等）任务承担单位科研作风学风和科研诚信主体责任的通知》要求，建立和完善科研诚信教育、管理监督制度。

二、切实贯彻《国家自然科学基金委员会关于进一步加强依托单位科学基金管理工作的若干意见》《国家自然科学基金依托单位基金工作管理办法》，认真履行管理主体责任，加强和规范科学基金项目管理。认真组织项目申请工作，注重提高项目申请质量，避免通过“全民动员”、设置硬性指标、实施与申请项目挂钩的奖惩措施等方式盲目追求项目申请数量。

三、严格按照《2026年度国家自然科学基金项目指南》《国家自然科学基金资助项目资金管理办法》有关申请的通知通告和相关类型项目管理办法等文件要求，认真审核所有申请材料，确保本单位所有申请材料的真实性、完整性和合法性；确保在申请材料中不出现任何违反法律法规、违反科研伦理的内容；确保申请材料中没有任何涉密信息或敏感信息；确保申请人符合相应项目的申请资格；确保申请人及主要参与者的职称信息准确；确保依托单位、合作研究单位、申请人及主要参与者不在限制申报、承担或参与财政性资金支持的科技活动的期限内。

四、在项目申请和评审活动全过程中，遵守有关评审规则和工作纪律，杜绝以下行为：

（一）以任何形式探听未公开的项目评审信息、评审专家信息及其他评审过程中的保密信息，干扰评审专家的评审工作；

（二）组织、协助或纵容申请人或参与者向评审工作人员、评审专家等提供任何形式的礼品、礼金、有价证券、支付凭证、商业预付卡、电子红包等；宴请评审工作人员、评审专家，或向评审工作人员、评审专家提供任何可能影响科学基金评审公正性的活动；

（三）支持申请人采取任何不正当手段获取国家自然科学基金项目申请资格；

（四）支持申请人或参与者虚假申报项目，甚至骗取国家自然科学基金项目；

（五）支持申请人或参与者采取请托、“打招呼”、“围会”等方式影响科学基金项目评审的公正性；

（六）拖延、包庇、阻碍、干扰请托案件等不端行为调查；

（七）其他违反财经纪律和相关管理规定的行为。

五、不从事危害国家安全、损害社会公共利益、危害人体健康、违背科研诚信和科技伦理的科学技术研究开发和应用活动。

如违背上述承诺，本单位愿接受自然科学基金委和相关部门做出的各项处理决定，包括但不限于停拨或核减经费、追回项目已拨经费、取消本单位一定期限国家自然科学基金项目申请资格、记入科研诚信严重失信行为数据库以及主要责任人接受相应党纪政务处分等。

依托单位公章:
日期： 年 月 日

合作研究单位公章:
日期： 年 月 日

合作研究单位公章:
日期： 年 月 日